



UNIVERSIDADE FEDERAL DE MINAS GERAIS
ESCOLA DE ENGENHARIA
DEPARTAMENTO DE ENGENHARIA QUÍMICA - DEQ

Daniel Couto Vieira
Guilherme Moura de Sousa Franco
Matheus Henrique Borba Póvoas
Rodrigo Amaral da Mata

**Modelagem Híbrida com Machine Learning aplicada a simulação de
processo de lixiviação de concentrado ustulado de zinco**

Belo Horizonte

2026

Daniel Couto Vieira

Guilherme Moura de Sousa Franco

Matheus Henrique Borba Póvoas

Rodrigo Amaral da Mata

**Modelagem Híbrida com Machine Learning aplicada a simulação de
processo de lixiviação de concentrado ustulado de zinco**

Relatório técnico apresentado como requisito
parcial para obtenção de aprovação na disciplina
Laboratório de Operações e Processos, no
Curso de Engenharia Química, na Universidade
Federal de Minas Gerais - UFMG.

Orientador: Prof Dr. Fabrício Bortot Coelho

Belo Horizonte

2026

RESUMO

Aa

Palavras-chave: Aa,

SUMÁRIO

1. INTRODUÇÃO.....	5
2. OBJETIVOS.....	6
2.1. OBJETIVO GERAL.....	6
2.2. OBJETIVOS ESPECÍFICOS.....	6
3. REVISÃO BIBLIOGRÁFICA.....	7
3.1. FUNDAMENTOS DE LIXIVIAÇÃO E CINÉTICA SÓLIDO-LÍQUIDO.....	7
3.1.1. Termodinâmica da Lixiviação.....	7
3.1.2. Métodos de Contato Sólido-Líquido.....	11
3.1.3. Modelos Cinéticos Heterogêneos e Mecanismos Controladores.....	14
3.1.3.1. Modelo do Núcleo Não Reagido (Shrinking Core Model).....	15
3.1.3.2. Modelo da Conversão Progressiva (Progressive Conversion Model).....	17
3.1.3.3. Diagnóstico Experimental dos Mecanismos Controladores.....	18
3.1.4. Sistema Sulfúrico de Zinco e Cinética de Concentrados Reais.....	22
3.1.4.1. Modelagem da lixiviação em regime batelada.....	27
3.1.4.1. Modelagem de Reatores Contínuos em Cascata.....	28
3.1.4.1. Limitações do Modelo Fenomenológico.....	29
3.2. APRENDIZADO DE MÁQUINA.....	30
3.2.1. Conceitos fundamentais e paradigmas de aprendizado.....	30
3.2.2. Algoritmos de regressão em engenharia de processos.....	31
3.2.3. Pré-processamento de dados e estratégias de validação.....	34
3.2.4. Avaliação de desempenho e generalização.....	35
3.3. APRENDIZADO DE MÁQUINA APLICADO À LIXIVIAÇÃO: AVANÇOS RECENTES E ANÁLISE DO ESTADO DA ARTE.....	37
3.3.1. Panorama das Aplicações de Dados em Sistemas de Lixiviação.....	37
3.3.2. Dinâmica operacional, desempenho algorítmico e limitações dos modelos caixa-preta.....	41
3.4. MODELAGEM HÍBRIDA.....	43
3.4.1. Conceito e motivação.....	43
3.4.2. Taxonomia estrutural: Hybrid Modeling Diamond.....	44
3.4.2.1. Arquitetura serial (Serial Hybrid: DDM para FPM).....	45
3.4.2.2. Arquitetura paralela cooperativa: modelagem residual.....	46
3.4.2.3. Arquitetura paralela competitiva: combinação de modelos.....	47
3.4.2.4. Arquitetura híbrida aumentada por conhecimento (Knowledge-Augmented Hybrid, KAH).....	48
3.4.3. O framework de extrapolação e transferência de aprendizado (transfer learning).....	49
3.4.4. Parâmetros para a seleção de arquiteturas e aplicação em sistemas de lixiviação.....	51
4. MATERIAIS E MÉTODOS.....	56
4.1. PROCEDIMENTOS EXPERIMENTAIS.....	56
4.2. AA.....	56
4.3. AA.....	56
5. RESULTADOS E DISCUSSÃO.....	56
5.1. AA.....	56
5.2. AA.....	56
5.3. AA.....	56

5.4. AA.....	56
6. CONCLUSÕES.....	56
7. REFERÊNCIAS BIBLIOGRÁFICAS.....	57
8. APÊNDICES.....	64
APÊNDICE A - XX.....	64

1. INTRODUÇÃO

2. OBJETIVOS

2.1. OBJETIVO GERAL

2.2. OBJETIVOS ESPECÍFICOS

3. REVISÃO BIBLIOGRÁFICA

3.1. FUNDAMENTOS DE LIXIVIAÇÃO E CINÉTICA SÓLIDO-LÍQUIDO

A lixiviação é a operação unitária de extração sólido-líquido na qual espécies metálicas de interesse presentes em uma matriz mineral são solubilizadas seletivamente pela ação de um agente químico em meio aquoso (Habashi, 1997). A descrição desse processo, apoia-se especialmente nos princípios de cinética química heterogênea e fenômenos de transporte, tratando a dissolução como um sistema reacional fluido-sólido não catalítico e governado por resistências em série (Levenspiel, 2000). Nesses sistemas, a velocidade global de extração resulta do acoplamento simultâneo entre forças motrizes termodinâmicas, transporte de reagentes e produtos através das camadas limites hidrodinâmicas e a cinética química na superfície da partícula mineral. Portanto, é necessário estabelecer o embasamento teórico e matemático necessário para a estruturação do modelo fenomenológico do processo.

No contexto da produção industrial de zinco pela rota hidrometalúrgica convencional, a lixiviação consiste no tratamento do concentrado previamente ustulado com soluções aquosas de ácido sulfúrico. O objetivo central dessa etapa é solubilizar o metal na forma de sulfato de zinco (ZnSO_4), gerando um licor aquoso enriquecido que, após passar por etapas de purificação para a remoção de impurezas metálicas, é encaminhado à eletrorrecuperação para a obtenção do zinco metálico de alta pureza (Habashi, 1997).

3.1.1. Termodinâmica da Lixiviação

A condição de ocorrência de lixiviação é dada pela espontaneidade termodinâmica das reações heterogêneas de dissolução, expressa pela variação negativa da energia livre de Gibbs do sistema. Na engenharia hidrometalúrgica, a análise sistemática dos equilíbrios entre as fases sólidas e a solução aquosa é tradicionalmente conduzida por meio dos diagramas de potencial de eletrodo versus pH, conhecidos como diagramas de Pourbaix (Pourbaix, 1974; Free, 2013). Esses diagramas mapeiam as regiões de estabilidade termodinâmica das espécies iônicas solúveis e dos compostos insolúveis em função do potencial de oxirredução e da acidez do meio reacional, permitindo prever as condições operacionais em que a extração metálica é espontânea.

A interpretação dos diagramas de Pourbaix é apoiada na delimitação de três domínios termodinâmicos fundamentais em relação às linhas de estabilidade da água: imunidade, passivação e corrosão (Pourbaix, 1974; Free, 2013). Enquanto na zona de imunidade o metal em estado elementar (M^0) permanece estável, o foco da operação de lixiviação reside na zona de corrosão ou dissolução. É dentro dos limites dessa janela que cátions livres ou oxianions solúveis constituem as fases de menor energia livre de Gibbs, definindo as condições de potencial redox e de acidez sob as quais a transferência do metal para a fase aquosa é termodinamicamente favorável. Já a zona de passivação, por sua vez, promove a formação de precipitados ou filmes de óxidos e hidróxidos refratários que blindam a superfície mineral, dificultando a sua extração (Crundwell et al., 2011).

Nesse contexto, as fronteiras que separam esses campos de estabilidade variam desde linhas horizontais e verticais, que descrevem equilíbrios regidos unicamente por transferência de elétrons ou por reações ácido-base sem variação de estado de oxidação, até linhas inclinadas, associadas a reações redox simultâneas (Habashi, 1997). O controle conjunto de potencial redox e pH permite, desse modo, posicionar o reator no interior do campo de solubilidade e evitar desvios para regiões de passivação.

No caso do processamento de concentrados de zinco, a avaliação das fronteiras de equilíbrio deve considerar não somente o zinco, mas também as demais espécies presentes na matriz sólida. Nesse cenário, o ferro destaca-se como a principal impureza associada ao concentrado, sendo responsável pela formação da fase refratária de ferrita de zinco ($ZnFe_2O_4$) durante a etapa prévia de ustulação. A Figura XX e Figura XX ilustram os diagramas Eh-pH para o sistema Zn-Fe- H_2O a 25°C e 1 atm, conforme delimitado por Bortot Coelho (2017) a partir de simulações termodinâmicas no software HSC Chemistry.




Figura XX: Diagrama de equilíbrio Eh-pH para as espécies de zinco no sistema Zn-Fe-H₂O a 25°C e 1 atm, avaliado para concentrações metálicas de 0,1 mol/L (linha contínua) e 1,0 mol/L (linha tracejada).

Fonte: Adaptado de Bortot Coelho (2017).




Figura XX: Diagrama de equilíbrio Eh-pH para as espécies de ferro no sistema Zn-Fe-H₂O a 25°C e 1 atm, avaliado para concentrações metálicas de 0,1 mol/L (linha contínua) e 1,0 mol/L (linha tracejada).

Fonte: Adaptado de Bortot Coelho (2017).

Os diagramas Eh-pH apresentados estabelecem a janela operacional termodinâmica para a lixiviação do concentrado ustulado (Bortot Coelho, 2017). Pelo diagrama de zinco, verifica-se que o óxido livre (ZnO) deixa de ser estável em valores de pH inferiores a 5,0; convertendo-se espontaneamente no cátion solúvel Zn²⁺ e viabilizando a extração do metal em licores sulfúricos diluídos. Por sua vez, o diagrama de ferro demonstra que, na faixa de potencial oxidante e de acidez moderada típica da lixiviação neutra, o ferro tende a se estabilizar como precipitado insolúvel (Fe₂O₃), minimizando a sua transferência indesejada para a solução aquosa.

Por outro lado, a fase refratária de ferrita de zinco (ZnFe₂O₄) ocupa um domínio amplo de estabilidade química na presença de ácido, confirmando a necessidade de etapas de lixiviação complementares para completa solubilização, empregando-se condições térmicas e ácidas mais severas. Desse modo, visto que a ferrita de zinco retém entre 10% e 15% do zinco total do concentrado ustulado, a sua estabilidade nas condições brandas da lixiviação neutra impõe um patamar máximo de conversão em torno de 85% a 90% ao processo (Balarini et al., 2025; Bortot Coelho, 2017).

Associada à estabilidade das espécies metálicas, a especiação química do agente lixiviante em solução aquosa determina a disponibilidade efetiva de reagente para a ocorrência da lixiviação. Em sistemas baseados em ácido sulfúrico (H₂SO₄), ocorrem duas etapas consecutivas de ionização:



Pelo princípio de Le Chatelier, a extensão da desprotonação do bissulfato (HSO₄⁻) diminui à medida que a acidez total da solução e temperatura do licor aumentam (Jackson, 1986). Como resultado, à medida que o reagente é consumido pela reação com os minerais e com a ganga, a acidez livre diminui e o equilíbrio se desloca

continuamente, gerando uma atenuação na força motriz que deve ser fielmente incorporada aos modelos matemáticos do processo.

3.1.2. Métodos de Contato Sólido-Líquido

Uma vez assegurada a termodinâmica favorável e conhecida a especiação do solvente, a engenharia de processos deve definir o modo de contato físico entre a fase aquosa e o sólido. Essa seleção é orientada pelo compromisso entre o consumo energético na cominuição do mineral e a taxa de transferência de massa do sistema. Nesse sentido, o tratamento de sólidos com granulometria grosseira dispensa etapas intensivas de moagem, porém resulta em processos lentos e governados pela difusão interna. Em contrapartida, concentrados finos demandam maior cominuição, mas asseguram cinéticas rápidas e elevada produtividade volumétrica (Habashi, 1997; Crundwell et al., 2011).

As atuais tecnologias hidrometalúrgicas para lixiviação organizam-se em dois regimes principais de contato:

- Sistemas estáticos (ou de leito poroso): caracterizam-se pela imobilidade da matriz sólida, na qual o agente lixiviante percola através dos vazios do leito mineral. São indicados para partículas grosseiras e operam com taxas de transferência de massa geralmente limitadas pela difusão intrapartícula.
- Sistemas dispersos (ou agitados): caracterizam-se na suspensão de partículas finamente cominuídas no seio da fase aquosa por meio de agitação mecânica ou pneumática. O cisalhamento reduz a camada limite líquida ao redor do sólido, favorecendo elevadas taxas de transferência de massa interfacial.

No contexto dos sistemas estáticos, a extração mineral varia conforme a disposição física e o confinamento da matéria-prima. Na lixiviação *in situ* (ISR), a dissolução é promovida no próprio depósito geológico por injeção e bombeamento de soluções, operando sob taxas governadas pela condutividade hidráulica do maciço rochoso (Aizhulov et al., 2024; Gupta e Mukherjee, 1990). Já na lixiviação em pilhas (heap leaching), o minério britado grosseiramente é disposto sobre bases impermeabilizadas para percolação gravitacional (Nie et al., 2026). Essa configuração pode ainda ser combinada à ação de microrganismos acidófilos para catalisar a oxidação de sulfetos e regenerar o agente oxidante no leito, caracterizando a biolixiviação autotrófica (Brierley e Brierley, 2001;

Pradhan et al., 2008). Por sua vez, a lixiviação em cubas (vat leaching) opera com leitos fixos inundados sob circulação forçada, sendo adotada para sólidos de granulometria intermediária e que demandam maior controle operacional, tais como minérios oxidados de cobre (Bravo-Gutiérrez et al., 2026) e areias uraníferas (Ouassel et al., 2025).

Em contrapartida, os sistemas dispersos exigem que o sólido seja previamente moído a partículas finas para permitir a sua suspensão na fase líquida. Na extração de ouro via cianetação, por exemplo, são usados tanques Pachuca pneumáticos, nos quais a aeração e o escoamento vertical são induzidos por injeção de ar comprimido sem peças mecânicas móveis (Dong et al., 2023; Alván Oliveira et al., 2023). Para o caso de matérias-primas refratárias sem resposta à pressão atmosférica, são empregadas autoclaves pressurizadas (HPAL), que combinam temperaturas de até 270 °C e sobrepressão de oxigênio para decompor quimicamente sulfetos e lateritas níquelíferas (Surya et al., 2025; Weng et al., 2025).

Para processamento de concentrados minerais finos, como é o caso da própria calcina de ustulação de zinco, o padrão industrial consolidado são tanques mecanicamente agitados (Zhou et al., 2023; Bortot Coelho, 2017). O cisalhamento turbulento gerado pelos impelidores mantém as partículas em suspensão completa e comprime a camada limite hidrodinâmica ao redor de cada sólido a espessuras mínimas. Desse modo, com a eliminação da resistência à transferência de massa no filme líquido, a taxa global de extração do zinco passa a depender estritamente da reação química ou da difusão na camada de produto, permitindo alcançar conversões mais elevadas em tempos relativamente curtos (Balarini et al., 2025).

A Tabela XX sintetiza as características operacionais, granulometrias típicas, etapas limitantes e aplicações típicas para as principais tecnologias industriais de lixiviação.

Tabela XX: Comparativo entre as principais tecnologias industriais de lixiviação

Método	Granulometria típica	Tempo de processo	Etapa limitante	Aplicações típicas
Lixiviação in situ (ISR)	Maciço rochoso natural	Meses a anos	Transporte hidrodispersivo e permeabilidade da rocha	Minérios permeáveis de urânio e cobre profundo
Lixiviação em Pilhas (Heap Leaching)	Grosseira (6 a 25 mm)	Meses a anos	Difusão intrapartícula na matriz mineral	Minérios oxidados de cobre, ouro e urânio de baixo teor
Bioliexiviação	Grosseira a média (6 a 20 mm)	Meses a anos	Difusão através de filmes bacterianos e camadas passivantes	Sulfetos secundários de cobre e refratários de ouro
Lixiviação em Cubas (Vat Leaching)	Média (1 a 10 mm)	Dias a semanas	Difusão intraporo e transferência de massa convectiva no leito	Minérios de teor médio de cobre oxidado e areias uraníferas
Autoclaves Pressurizadas (HPAL)	Fina (< 150 μm)	30 a 90 min	Reação química superficial ou difusão na camada de produto	Lateritas niquelíferas limoníticas e calcopirita
Tanques Pachuca	Fina (< 100 μm)	Horas a dias	Difusão intrapartícula com taxa limitada pelo suprimento de oxigênio	Cianetação de ouro e prata, polpas finas de urânio
Tanques Mecanicamente	Fina (< 75 μm)	30 a 120 min	Reação química superficial ou difusão na	Concentrados ustulados de zinco, bauxita

Agitados	camada de produto	e poeiras metalúrgicas
----------	----------------------	---------------------------

Fonte: Elaborado pelos autores a partir de Aizhulov et al. (2024), Alván Oliveira et al. (2023), Bortot Coelho (2017), Bravo-Gutiérrez et al. (2026), Crundwell et al. (2011), Dong et al. (2023), Gupta e Mukherjee (1990), Habashi (1997), Kim et al. (2026), Nie et al. (2026), Ouassel et al. (2025), Pradhan et al. (2008), Razzani et al. (2026), Surya et al. (2025), Weng et al. (2025) e Zhou et al. (2023).

3.1.3. Modelos Cinéticos Heterogêneos e Mecanismos Controladores

A velocidade global de dissolução em sistemas de lixiviação é descrita pela teoria das reações heterogêneas não catalíticas entre fluidos e sólidos. Nesses processos, a transformação química resulta de uma sequência de etapas físicas de transporte de matéria e etapas químicas interfaciais dispostas em série (Levenspiel, 2000; Szekely et al., 1976). Para uma partícula mineral suspensa em meio lixivante, o mecanismo global compreende cinco etapas sucessivas:

1. Transporte do reagente aquoso do seio da solução através do filme líquido estagnado que envolve a partícula até a superfície externa do sólido;
2. Difusão do reagente através dos poros da camada residual inerte (de cinzas ou de produto) até a interface de reação;
3. Reação química heterogênea entre o agente lixivante e as espécies metálicas na interface sólida;
4. Difusão dos produtos solúveis através da camada de produto em sentido inverso, em direção à superfície externa;
5. Transferência de massa dos produtos através do filme líquido interfacial em direção ao seio do licor.

Por se tratar de um circuito de fenômenos em série, a velocidade global do processo é ditada pela etapa que oferece a maior resistência ao avanço reacional, denominada etapa

controladora (Levenspiel, 2000). Pelo mesmo raciocínio, quando duas ou mais etapas exibem resistências de ordens de grandeza semelhantes, o processo opera sob regime de controle misto. Nesse sentido, para expressar matematicamente a evolução da conversão da partícula no tempo, a literatura em Engenharia Química fundamenta-se tradicionalmente em duas abordagens físico-químicas: o Modelo do Núcleo Não Reagido (Shrinking Core Model - SCM) e o Modelo da Conversão Progressiva (Progressive Conversion Model - PCM).

3.1.3.1. Modelo do Núcleo Não Reagido (Shrinking Core Model)

O Modelo do Núcleo Não Reagido assume que a partícula sólida é impermeável ao reagente lixiviante, de modo que a reação química ocorre estritamente em uma frente de ataque nítida e bem delimitada. À medida que a dissolução progride, essa interface avança em direção ao centro do sólido, fazendo com que o núcleo não reagido encolha continuamente enquanto uma camada porosa de produto residual (camada de cinzas) é deixada para trás (Levenspiel, 2000; Habashi, 1997). A evolução morfológica da partícula e as regiões físicas de transporte de massa estão representadas esquematicamente na Figura XX.




Figura XX: Representação esquemática do avanço do Modelo do Núcleo Não-Reagido ao longo do tempo para uma partícula sólida esférica,

Fonte: Adaptado de Da Rocha et al. (2013).

Considerando partículas esféricas de tamanho constante cercadas por um filme fluido em regime quase permanente, a integração da equação de taxa conduz às seguintes relações

analíticas entre o tempo de reação (t), o tempo para conversão completa da partícula (τ) e a conversão fracionária do sólido (X):

1. Controle pela transferência de massa no filme líquido externo:

$$\frac{t}{\tau} = X \quad \tau = \frac{\rho_B R_0}{3 b k_g C_{A0}}$$

2. Controle pela difusão através da camada de produto:

$$\frac{t}{\tau} = 1 - 3(1 - X)^{2/3} + 2(1 - X) \quad \tau = \frac{\rho_B R_0^2}{6 b D_e C_{A0}}$$

3. Controle por reação química na interface do núcleo não reagido:

$$\frac{t}{\tau} = 1 - (1 - X)^{1/3} \quad \tau = \frac{\rho_B R_0}{b k_s C_{A0}}$$

Nas equações integradas, ρ_B representa a densidade molar do reagente sólido no mineral, R_0 é o raio inicial da partícula, b é o coeficiente estequiométrico do reagente sólido na reação, C_{A0} é a concentração de reagente no seio da solução, k_g é o coeficiente de transferência de massa no filme, D_e é a difusividade efetiva na camada porosa e k_s é a constante de velocidade da reação química superficial.

A validade matemática das soluções analíticas integradas do Modelo do Núcleo Não Reagido fundamenta-se na Hipótese do Estado Quase Permanente (PSSA) (Bischoff, 1963). Essa simplificação é fisicamente justificada pela grande disparidade entre a densidade molar do sólido reativo e a concentração do agente lixiviante em solução. Sendo essa diferença de duas a três ordens de grandeza, a frente de reação recua lentamente e o acúmulo de reagente nos poros é desprezível ($\partial C_A / \partial t \approx 0$), permitindo resolver o perfil difusivo em regime quase estacionário (Szekely et al., 1976; Levenspiel, 2000).

Adicionalmente, Levenspiel (2000) e Dickinson e Heal (1999) destacam que o modelo assume duas formas físicas distintas: partículas de tamanho constante, quando a camada residual de produto ou ganga insolúvel permanece no exterior, e partículas em

encolhimento contínuo, nas quais o sólido se solubiliza integralmente, levando à diminuição do raio externo em sincronia com o avanço da dissolução.

3.1.3.2. Modelo da Conversão Progressiva (Progressive Conversion Model)

Por sua vez, o Modelo da Conversão Progressiva aplica-se a partículas sólidas de elevada porosidade inicial, nas quais a resistência à difusão nos poros internos é pequena em relação à cinética interfacial. Sob essa hipótese, o reagente líquido consegue permear toda a matriz porosa desde o início do processo, de modo que a reação química se desenvolve simultaneamente em todo o volume do sólido, sem formação de uma frente de reação concentrada (Levenspiel, 2000; Sohn e Wadsworth, 1979).

A evolução temporal do perfil de concentração do sólido e a natureza volumétrica do Modelo da Conversão Progressiva estão ilustradas na Figura XX. A partir da transformação química simultânea em toda a extensão do sólido, percebe-se o decréscimo contínuo da concentração do reagente sólido longo de toda a posição radial, sem a existência de uma fronteira interfacial delimitada.




Figura XX: Representação esquemática do Modelo da Conversão Progressiva ao longo do tempo para uma partícula esférica porosa.

Fonte: Adaptado de Mousa e Najem (2024), baseado em Levenspiel (2000)

A partir da hipótese de conversão uniforme em toda a matriz porosa, a integração da taxa reacional conduz à seguinte relação cinética linear (Levenspiel, 2000):

$$- \ln(1 - X) = k t$$

Porém, os estudos experimentais dedicados à lixiviação de concentrados ustulados densos demonstram que os dados de dissolução desviam acentuadamente dessa linearidade (Balarini et al., 2025; Bortot Coelho, 2017). Nesse sentido, é evidente que a matriz mineral não reage de forma homogênea em todo o volume, consolidando o Modelo do Núcleo Não Reagido como a formulação adequada para descrever o avanço reacional do sistema.

3.1.3.3. Diagnóstico Experimental dos Mecanismos Controladores

A identificação do mecanismo que rege a velocidade de dissolução exige a condução de ensaios cinéticos dedicados em escala de bancada e o confronto dos dados experimentais com as equações dos modelos apresentadas em 3.1.3.1. De acordo com Prosser (1996) e Balarini (2009), a taxa global de lixiviação é influenciada primariamente por cinco variáveis operacionais controláveis: a intensidade de agitação da mistura, a temperatura do meio reacional, a granulometria inicial das partículas, o tempo de contato e a concentração do agente lixiviante (Bortot Coelho, 2017). A análise sistemática da sensibilidade da velocidade reacional frente a cada um desses parâmetros fornece o diagnóstico do regime limitante.

A intensidade de agitação atua como a principal ferramenta diagnóstica para avaliar a influência dos efeitos hidrodinâmicos externos sobre a velocidade global do processo. Dentre todas as etapas que compõem o mecanismo heterogêneo em série, a transferência de massa através do filme líquido interfacial é a única etapa fisicamente sensível à agitação mecânica da polpa (Levenspiel, 2000; Prosser, 1996).

Em velocidades de rotação baixas ou intermediárias, o aumento da agitação eleva o número de Reynolds local, promovendo cisalhamento hidrodinâmico que comprime a espessura da camada limite de fluido ao redor de cada partícula sólida. Como consequência, a resistência ao transporte de matéria decresce e a taxa de extração se eleva continuamente. Entretanto, a camada limite atinge uma espessura mínima a partir

de uma rotação crítica, além da qual incrementos adicionais na velocidade do impelidor não provocam qualquer alteração na velocidade de dissolução. A transição entre esse regime dependente e o surgimento do patamar independente está ilustrada na Figura XX.




Figura XX: Variação da taxa de extração em função da velocidade de agitação mecânica, evidenciando o regime de controle por filme fluido e a transição para o patamar de controle intrínseco.

Fonte: Adaptado de Bortot Coelho (2017), com base em Sohn e Wadsworth (1979).

Por sua vez, a influência da temperatura fundamenta-se no fato de que as reações químicas interfaciais são significativamente mais sensíveis ao aporte térmico do que os fenômenos físicos de transporte molecular (Levenspiel, 2000). A quantificação dessa dependência é realizada pelo cálculo da energia de ativação aparente (E_a) a partir da linearização da equação de Arrhenius:

$$k = k_0 \exp\left(-\frac{E_a}{R T}\right) \quad \Rightarrow \quad \ln(k) = \ln(k_0) - \frac{E_a}{R} \frac{1}{T}$$

Conforme estabelecido por Prosser (1996), valores de energia de ativação iguais ou superiores a 25 kJ/mol são tradicionalmente associados ao controle por reação química superficial, ao passo que magnitudes inferiores caracterizam processos regidos por transporte de massa na camada de fluido ou por difusão na camada de cinzas. Em adição, Prosser (1996) e Bortot Coelho (2017) ressaltam que a temperatura, isoladamente, não é

um diagnóstico conclusivo. Em determinados sistemas minerais, tal como o próprio concentrado ustulado de zinco (Balarini et al., 2025), reações interfaciais de baixa barreira de energia podem exibir valores de E_a inferiores a 25 kJ/mol. Além disso, o ajuste de Arrhenius pode apresentar desvios de linearidade ou inflexões com duas inclinações distintas em faixas térmicas amplas, indicando a transição de um regime químico em baixas temperaturas para um regime difusional em temperaturas elevadas.

O tamanho de partícula (R_0) compreende o critério geométrico mais rigoroso para diferenciar a difusão na camada de produto da reação química. Segundo Levenspiel (2000), o tempo necessário para a conversão completa da partícula (τ) varia com o raio inicial segundo expoentes característicos:

- $\tau \propto R_0^{1,0 \text{ a } 2,0}$: para controle pelo filme líquido (o expoente diminui com o aumento da turbulência e do número de Reynolds);
- $\tau \propto R_0^2$: para controle pela difusão intrapartícula através da camada de produto;
- $\tau \propto R_0$: para controle pela reação química interfacial.

Para que a análise granulométrica seja válida como ferramenta diagnóstica, os ensaios de bancada exigem o fracionamento prévio do sólido em classes granulométricas monodispersas, obtidas por peneiramento em malhas estreitas com diâmetros muito próximos de um valor médio conhecido (Bortot Coelho, 2017). Caso a matéria-prima seja ensaiada em seu estado natural polidisperso, a sobreposição das cinéticas de partículas distintas mascara o expoente de R_0 , tornando indispensável o recurso a modelos baseados em balanço populacional (Crundwell e Bryson, 1992; Herbst, 1979), melhor explicado em 3.1.4.X.

Nesse sentido, o avanço da fração convertida ao longo do tempo permite a verificação do ajuste dos dados experimentais aos modelos matemáticos. Conforme proposto por Prosser (1996) e Levenspiel (2000), cada mecanismo deduzido no Modelo do Núcleo Não Reagido (3.1.3.1) conduz a uma função de conversão específica que, quando plotada contra o tempo de lixiviação (t), deve resultar em uma linha reta passando pela origem. A adequação estatística da reta via coeficiente de determinação (R^2) e constância da inclinação angular ($1/\tau$), para diferentes ensaios, indicam a validade do mecanismo avaliado (Balarini, 2009).

Por fim, a concentração do agente lixiviante em solução atua na determinação da ordem aparente da reação. Nos processos regidos por transporte de massa no filme ou por difusão nas cinzas, a força motriz é dada estritamente pela diferença de concentração das espécies difusoras, de modo que a inclinação das retas cinéticas ($1/t$) é linearmente proporcional à concentração do reagente líquido (Ca_0), caracterizando uma ordem unitária aparente (Prosser, 1996). Por outro lado, quando o processo é controlado pela cinética química superficial, a dependência pode assumir ordens fracionárias ou superiores (Bortot Coelho, 2017).

A Tabela XX consolida o conjunto de evidências experimentais associadas a cada um dos três mecanismos controladores clássicos da lixiviação, conforme sistematizado por Balarini (2009).

Tabela XX: Síntese das evidências experimentais características para identificação da etapa controladora em reações de lixiviação

Variável Investigada	Transporte no Filme Líquido Interfacial	Difusão na Camada de Produto	Reação Química Superficial Interfacial
Intensidade de Agitação	Taxa sensível a níveis moderados de rotação	Taxa independente da agitação	Taxa independente da agitação
Energia de Ativação (E_a)	Baixa	Baixa a moderada	Geralmente elevada
Linearização Cinética (X vs t)	Linear para o gráfico de X vs t	Linearidade no gráfico da equação XX.	Linearidade no gráfico da equação YY
Tamanho de Partícula (R_0)	Tempo de conversão proporcional a $R_0^{1,0 \text{ a } 2,0}$	Tempo de conversão proporcional a R_0^2	Tempo de conversão proporcional a R_0
Concentração de Reagente (Ca_0)	Taxa linearmente proporcional à concentração	Taxa linearmente proporcional à concentração	Dependência variável de acordo com a ordem de reação

Fonte: Elaborado pelos autores a partir de Balarini (2009), Prosser (1996) e Bortot Coelho (2017).

A relação de variáveis apresentada na Tabela XX estabelece a análise padrão de dados cinéticos de bancada. Porém, a transposição desses critérios idealizados para sistemas industriais reais, como o concentrado ustulado de zinco, enfrenta desafios de ordem física. Isso se dá uma vez que as matérias-primas não se comportam como partículas esféricas isoladas de raio constante, mas sim compõem suspensões polidispersas associadas a fases minerais refratárias e com variações dinâmicas de acidez livre (Bortot Coelho, 2017). Diante dessas não idealidades, é indispensável examinar a cinética de lixiviação e a formulação do balanço populacional acoplado a parâmetros empíricos de ajuste, que constituem o objeto da seção 3.1.4.

3.1.4. Sistema Sulfúrico de Zinco e Cinética de Concentrados Reais

Em contraste às condições idealizadas trazidas na seção anterior, a prática industrial hidrometalúrgica opera invariavelmente com suspensões minerais complexas que se afastam substancialmente de simetrias geométricas, monodispersão de tamanhos e homogeneidade mineralógica. Nos circuitos reais de lixiviação, a velocidade global de extração é condicionada pela sobreposição simultânea de três não idealidades físicas fundamentais:

- Polidispersão granulométrica da alimentação sólida;
- Coexistência de múltiplas fases minerais com reatividades químicas distintas;
- Variação dinâmica da concentração do agente lixiviante provocada por reações paralelas de consumo de acidez livre por impurezas da ganga.

No contexto da metalurgia extrativa do zinco, a matéria-prima preponderante alimentada na etapa de lixiviação atmosférica convencional é o concentrado ustulado de zinco, comumente denominado calcina. Sua caracterização física, química e mineralógica foi utilizada nos estudos de Bortot Coelho (2017) e Balarini et al. (2025), sendo a matéria-prima proveniente da unidade metalúrgica da Nexa Resources, em Três Marias (MG).

Nesse sentido, os estudos evidenciam a alta complexidade da matriz sólida. As análises

por fluorescência de raios X e difração de raios X revelam teores globais de zinco entre 55% e 65% em massa, acompanhados por 4% a 8% de ferro total e proporções menores de chumbo, cobre, cádmio, cálcio e sílica. Sob a perspectiva cristalográfica, a espécie predominante é a zincita (ZnO), correspondente ao óxido de zinco livre com estrutura hexagonal, perfazendo cerca de 76,1% da massa total do concentrado ustulado. Conforme discutido na Seção 3.1.1, a zincita representa a fração de lixiviação rápida do sistema, caracterizada por cinética acelerada e dissolução quase instantânea na presença de soluções ácidas moderadas.

Em contrapartida, a reação em estado sólido entre o óxido de ferro gerado e o óxido de zinco durante a ustulação promove a formação inevitável da ferrita de zinco (ZnFe_2O_4). Esse composto cristaliza em uma estrutura cúbica do tipo espinélio, caracterizada por empacotamento iônico denso e elevada estabilidade reticular. Por essa razão, a ferrita comporta-se como fase refratária, resistindo fortemente ao ataque em licores sulfúricos diluídos nas temperaturas brandas praticadas na lixiviação neutra industrial. Além da ferrita, identificam-se frações residuais de esfalerita não oxidada no forno, anglesita insolúvel e silicatos de zinco, como a willemita.

A Tabela XX sintetiza as principais fases minerais constituintes do concentrado ustulado de zinco, suas respectivas proporções em massa típicas, fórmulas químicas e respostas cinéticas frente à lixiviação sulfúrica em condições moderadas.

Tabela XX: Composição mineralógica típica do concentrado ustulado de zinco e comportamento químico das fases frente ao ataque com ácido sulfúrico diluído.

Fase Mineral	Fórmula Química	Fração típica em massa (%)	Comportamento cinético em meio sulfúrico moderado
Zincita	ZnO	70-78%	Dissolução muito rápida com controle por reação química superficial interfacial
Ferrita de Zinco	ZnFe_2O_4	10-16%	Refratária em condições brandas

Esfalerita	ZnS	1-3%	Inerte na ausência de agentes oxidantes fortes
Anglesita	PbSO ₄	1-3%	Completamente insolúvel
Willemita	Zn ₂ SiO ₄	1-2%	Lixiviação lenta acompanhada por dissolução de sílica
Silicatos e ganga	SiO ₂ aluminossilicatos	3-6%	Predominantemente inertes

Fonte: Elaborado pelos autores a partir de Balarini (2009), Balarini et al. (2025), Bortot Coelho (2017), Crundwell et al. (2011), Filippou e Demopoulos (1992), Habashi (1997), Prosser (1996) e Scott et al. (1986).

Além da heterogeneidade de fases, a quebra da hipótese de tamanho de partícula uniforme é o segundo obstáculo crítico na modelagem de sistemas reais. No caso da calcina de zinco avaliada por Bortot Coelho (2017), as partículas abrangem desde frações ultrafinas inferiores a 2 µm até grãos grosseiros superiores a 74 µm, com diâmetro médio volumétrico situado na faixa de 20 a 30 µm. Nesse sentido, a polidispersão desencadeia um comportamento dinâmico complexo no interior do reator de mistura. As partículas finas, dotadas de elevada área superficial específica, reagem e desaparecem completamente nos minutos iniciais de contato, enquanto as partículas grosseiras permanecem em processo contínuo de encolhimento, reduzindo progressivamente a área interfacial global disponível e alterando a densidade numérica de sólidos na polpa.

Dessa forma, para quantificar a polidispersão da alimentação, a distribuição granulométrica acumulada do concentrado ustulado foi avaliada experimentalmente por difração a laser e ajustada a funções matemáticas clássicas de distribuição de tamanhos (Bortot Coelho, 2017). Entre os vários modelos investigados na literatura mineral, como a formulação de Gates-Gaudin-Schuhmann (GGS) e a distribuição Sigmoidal, o modelo de Rosin-Rammler-Bennet (RRB) foi o que proporcionou o ajuste estatístico mais fiel à

calcina, com coeficiente de determinação R^2 superior a 0,99. A equação acumulada do modelo é expressa por:

$$F(D) = 1 - \exp\left[-\left(\frac{D}{D'}\right)^m\right]$$

Nessa expressão, $F(D)$ representa a fração mássica acumulada de partículas com diâmetro menor ou igual a D , a variável D' é o diâmetro característico da amostra correspondente à abertura de malha na qual passam 63,2% do material em massa, e o expoente adimensional m representa o módulo de dispersão ou uniformidade da amostra. No experimento conduzido por Bortot Coelho (2017), os parâmetros calibrados para a calcina de zinco resultaram em $D' \approx 25,4 \mu\text{m}$ e $m \approx 1,15$, confirmando a assimetria e amplitude da curva granulométrica.

Derivando a função acumulada em relação ao diâmetro de partícula, obtém-se a função densidade de distribuição de frequência inicial do número de sólidos, dada por:

$$f_0(D) = \frac{dF(D)}{dD} = \frac{m}{D'} \left(\frac{D}{D'}\right)^{m-1} \exp\left[-\left(\frac{D}{D'}\right)^m\right]$$

Essa equação é essencial para o modelo cinético, pois atua como condição inicial obrigatória da população de sólidos que entra no reator. Desse modo, permite que a taxa de dissolução considere a fração de massa associada a cada diâmetro de partícula ao longo do tempo, servindo de base tanto para ensaios em batelada quanto em operação contínua.

Independentemente do modo de operação do reator, a taxa microscópica com que o diâmetro de uma partícula individual diminui no tempo (dD/dt) rege o avanço físico da dissolução. Aplicando a consideração de partícula esférica e adotando controle por reação química interfacial, a taxa de consumo de matéria sólida por diminuição do volume esférico pode ser obtida diferenciando a sua massa molar no tempo através da regra da cadeia (Levenspiel, 2000; Fogler, 2006):

$$-\frac{dN_B}{dt} = -\frac{d}{dt} \left(\rho_s \frac{\pi}{6} D^3 \right) = -\frac{\pi \rho_s D^2}{2} \frac{dD}{dt}$$

Onde D é o diâmetro da partícula em dissolução e ρ_s é a densidade molar do óxido de zinco puro no mineral, calculada em aproximadamente 69,2 mol/L

Por outro lado, pela lei de ação das massas para reações heterogêneas na interface sólida, o consumo molar é dado pelo produto entre a área superficial externa da esfera e a taxa reacional específica de primeira ordem (Levenspiel, 2000; Sohn e Wadsworth, 1979):

$$- \frac{dN_B}{dt} = (\pi D^2) k_s C_A$$

Nesse viés, ao igualar as equações XX e XX, obtém-se a expressão clássica para a velocidade de retração do diâmetro da partícula para sistemas sem camada refratária de produto:

$$\frac{dD}{dt} = - \frac{2}{\rho_s} k_s C_A$$

Porém, na dissolução da calcina de zinco, a taxa de ataque à superfície mineral sofre um amortecimento progressivo em função do consumo de ácido livre, de variações na força iônica da solução e de resistências estéricas locais associadas às fases secundárias presentes. Para incorporar esse retardamento na lixiviação, Bortot Coelho (2017) e Balarini et al. (2025) modificaram a lei de retração linear, inserindo um parâmetro empírico de ajuste adimensional denominado α :

$$\frac{dD}{dt} = - \frac{2}{\rho_s} [k_s C_{Af} - \alpha(C_{A0} - C_{Af})]$$

Nessa relação, k_s é a constante cinética superficial estimada em $1,8 \times 10^4 \mu\text{m}/\text{min}$ para uma temperatura de 30 °C (Bortot Coelho, 2017), enquanto C_{A0} e C_{Af} indicam as concentrações inicial e instantânea de ácido sulfúrico livre na solução aquosa. Essa expressão também incorpora o termo $\alpha(C_{A0} - C_{Af})$ para a diminuição da velocidade reacional, sendo válida para a partícula em qualquer regime de contato.

3.1.4.1. Modelagem da lixiviação em regime batelada

Ao se considerar a condução da lixiviação em reatores batelada, o sistema comporta-se de forma transiente, com acúmulo e consumo contínuos ao longo do tempo. Nesse cenário, o desaparecimento das partículas finas e a diminuição simultânea do tamanho das partículas maiores exigem a formulação de um Balanço Populacional unidimensional em batelada (Randolph e Larson, 1988; Herbst, 1979), fundamentado na conservação do número de partículas sólidas no espaço de tamanhos:

$$\frac{\partial n(D, t)}{\partial t} + \frac{\partial [G(D, t) n(D, t)]}{\partial D} = 0$$

Nela, $n(D, t)$ representa a densidade populacional contínua de sólidos no tempo t para o diâmetro D , e $G(D, t) = dD/dt$ é exatamente a taxa linear de dissolução da partícula deduzida na Seção anterior. A condição inicial do sistema é dada pela população inicial (N_t) ponderada pelo modelo RRB, expressa por:

$$n(D, 0) = N_T f_0(D)$$

Além disso, é fundamental encontrar uma equação que expresse a conversão fracionária da fase ZnO. Para isso, é possível fazer uso da teoria de processos particulados, na qual o terceiro momento da função de distribuição granulométrica apresentada na Seção anterior expressa o volume total de sólidos presentes no sistema (Randolph e Larson, 1988). Dessa forma, a conversão da fase zincita em função do tempo de reação em batelada é dada pela razão entre o volume dissolvido e o volume inicial de sólidos alimentados (LeBlanc e Fogler, 1987; Bortot Coelho, 2017):

$$X_{ZnO}(t) = 1 - \frac{\int_0^{\infty} D^3 n(D, t) dD}{\int_0^{\infty} D^3 n_0(D) dD}$$

A expressão XX abaixo, desse modo, pode ser usada para a extração total de zinco, computando tanto o efeito impeditivo da fração insolúvel, quanto o rendimento máximo experimental característico da lixiviação neutra (85-90%), discutida na Seção 3.1.1:

$$X_{global}(t) = X_{max} \cdot X_{ZnO}(t)$$

Por fim, o consumo do agente lixiviante no regime batelada é obtido pelo balanço de massa na fase líquida. A redução da concentração de ácido sulfúrico no licor decorre do consumo estequiométrico gerado pela dissolução de todas as frações de tamanho presentes na polpa mineral, sendo expressa por (LeBlanc e Fogler, 1987; Bortot Coelho, 2017):

$$-\frac{dC_A}{dt} = \frac{b \pi \rho_s}{2 V_{liq}} \int_0^\infty D^2 \left(-\frac{dD}{dt}\right) n(D, t) dD$$

Na integral, b representa o coeficiente estequiométrico da reação, e V_{liq} denota o volume total de líquido contido no tanque. Essa expressão governa a queda contínua da concentração de ácido, fornecendo o valor de C_A que retroalimenta a velocidade de dissolução a cada instante.

3.1.4.1. Modelagem de Reatores Contínuos em Cascata

A transposição das equações de bancada para regime contínuo exige alterações nas equações, visto que os reatores operam sob alimentação e descarga contínuas de polpa. No estudo de Bortot Coelho (2017), duas abordagens clássicas foram desenvolvidas para modelar a cascata de três reatores CSTR em série.

Primeiramente, foi estudado o Modelo de Mistura Perfeita com Balanço Populacional em estado estacionário. Diferentemente da batelada, o reator contínuo em estado estacionário não apresenta acúmulo temporal, surgindo em seu lugar os termos convectivos de entrada e saída de sólidos. Para cada reator i da cascata, a equação de conservação contínua de partículas assume a seguinte forma (Bortot Coelho, 2017):

$$\frac{n_{in,i}(D) - n_{out,i}(D)}{\tau_{res,i}} - \frac{d[G(D) n_{out,i}(D)]}{dD} = 0$$

Sendo τ_{res} o tempo de residência espacial médio do tanque. Além disso, $n_{in,i}(D)$ e $n_{out,i}(D)$ representam as densidades populacionais de sólidos nas correntes de

alimentação e descarregamento do estágio i , respectivamente.

Da mesma forma, a concentração de ácido livre não decai continuamente no tempo tal como em batelada, mas permanece em um valor fixo para cada tanque da cascata, sendo determinado pelo balanço algébrico entre a vazão de entrada de ácido, o consumo na suspensão e a vazão de saída para o estágio seguinte.

Em segundo lugar, foi trazido por Bortot Coelho (2017) o Modelo de Fluxo Segregado com base na Distribuição de Tempos de Residência (DTR). Nessa metodologia, a conversão na saída da cascata não é descrita como uma curva transiente no tempo $X(t)$, mas como um valor médio constante ($\bar{X}$), dado pela integral abaixo:

$$\bar{X} = \int_0^{\infty} X_{batelada}(t) \cdot E(t) dt$$

A expressão $\bar{X}$ é calculada pela convolução direta entre a cinética medida em batelada e a probabilidade de permanência dos elementos fluidos no sistema, sendo esta governada pela curva experimental $E(t)$, medida com traçadores na planta piloto.

3.1.4.1. Limitações do Modelo Fenomenológico

Apesar da consistência física do modelo fenomenológico desenvolvido por Bortot Coelho (2017), sua formulação apresenta uma fragilidade estrutural que define o objetivo central do presente trabalho. Para ambos os regimes, o parâmetro empírico de correção α foi calibrado por regressão não linear de mínimos quadrados de maneira individual e estática para cada ensaio experimental, variando conforme a temperatura, a concentração inicial de ácido e a razão sólido-líquido. Como consequência, o valor do parâmetro opera como uma constante local restrita às condições testadas, não possuindo capacidade de generalização preditiva para tarefas de otimização e controle de processos industriais.

Para contornar essa restrição, este trabalho propõe o desenvolvimento de uma modelagem híbrida do tipo caixa-cinza, unindo a segurança dos balanços mecanísticos fundamentais à capacidade preditiva de algoritmos supervisionados (Sansana et al., 2024; Shah et al., 2024). Nessa abordagem, a estrutura determinística preserva os balanços estequiométricos de massa e a equação diferencial do Balanço Populacional,

enquanto o aprendizado de máquina é empregado para estimar o parâmetro α como uma função contínua das principais variáveis operacionais do processo:

$$\alpha = f(T, C_{A0}, \eta)$$

Em que T é a temperatura do meio reacional, C_{A0} representa a concentração inicial de ácido sulfúrico e η a razão molar estequiométrica entre o reagente lixiviante e o óxido de zinco. A fundamentação dos algoritmos de aprendizado de máquina adotados para essa etapa é apresentada na Seção 3.2, enquanto a formalização detalhada da arquitetura e das camadas da modelagem híbrida é aprofundada na Seção 3.4.

3.2. APRENDIZADO DE MÁQUINA

O Aprendizado de Máquina, *Machine Learning*, constitui um subcampo da Inteligência Artificial dedicado ao desenvolvimento de algoritmos e modelos estatísticos capazes de identificar padrões subjacentes, extrair inferências e generalizar comportamentos a partir de dados empíricos, sem a necessidade de parametrização analítica prévia (Bishop, 2006). No contexto da Engenharia Química, o interesse por essas ferramentas cresce progressivamente devido à elevada não linearidade, acoplamento multivariável e complexidade fenomenológica dos processos industriais, cuja descrição por primeiros princípios frequentemente demanda simplificações excessivas ou parâmetros de ajuste restritos a condições laboratoriais. (Venkatasubramanian, 2019).

3.2.1. Conceitos fundamentais e paradigmas de aprendizado

A formulação matemática e conceitual clássica do aprendizado de máquina foi estabelecida por Mitchell (1997), a qual postula que um programa de computador aprende a partir da experiência E , com respeito a uma determinada classe de tarefas T e sob uma métrica de desempenho P , se o seu desempenho na execução das tarefas em T , medido por P , melhora proporcionalmente com o acúmulo da experiência E . Na modelagem de processos químicos, por exemplo, a tarefa T comumente reside na predição de grandezas de estado ou parâmetros cinéticos; a experiência E é representada por matrizes de dados históricos ou ensaios experimentais, como dados de concentração e temperatura; e a métrica P corresponde a funções de custo ou medidas estatísticas de aderência, a exemplo do erro quadrático médio.

Os métodos de aprendizado de máquina são classificados em três paradigmas operacionais, diferenciados pelo mecanismo de fornecimento de informações e pelo objetivo do treinamento (Russel et.al, 2010). Em primeiro lugar, o Aprendizado Supervisionado caracteriza-se quando o algoritmo recebe um conjunto de treinamento constituído por pares ordenados (x_i, y_i) . Dessa forma, o objetivo primordial consiste em induzir uma função que aproxime com precisão a relação subjacente entre entradas e saídas, permitindo inferir y para novas instâncias de x não observadas durante a etapa de ajuste (MURPHY, 2012).

Em segundo lugar, no Aprendizado Não Supervisionado o conjunto de dados é formado exclusivamente por vetores de atributos de entrada x_i , sem a presença de variáveis de saída ou respostas anotadas. A finalidade do modelo é detectar a estrutura intrínseca, distribuições de probabilidade ou correlações nos dados, o que permite ele operar em tarefas de agrupamento (clustering), detecção de anomalias operacionais e redução de dimensionalidade, como na Análise de Componentes Principais (PCA) (Hastie et.al, 2009).

Por outro lado, o Aprendizado por Reforço estrutura-se sobre a interação dinâmica entre um agente decisor e o ambiente, formalizada por Processos de Decisão de Markov. O agente não é instruído diretamente sobre qual ação tomar, mas aprende uma política de controle ótima por tentativa e erro, orientado por sinais de recompensa ou penalização cumulativos, com ampla aplicação em controle avançado de processos e otimização dinâmica de plantas (Sutton, Barto, 2018).

3.2.2. Algoritmos de regressão em engenharia de processos

Na modelagem empírica de processos químicos e hidrometalúrgicos, a tarefa de regressão consiste em estabelecer um mapeamento contínuo entre um vetor de variáveis operacionais independentes, como temperatura (T), concentração de reagente lixiviante (C), tamanho de partícula (d_p), razão sólido-líquido (S/L) e tempo de reação (t) junto de uma ou mais variáveis de resposta dependentes, como o grau de conversão (X) ou a taxa reacional aparente (r).

A literatura de Engenharia de Sistemas em Processos consolidou três classes principais de algoritmos supervisionados para lidar com a não linearidade desses sistemas: o Perceptron Multicamadas, as Florestas Aleatórias e a Regressão por Vetores de Suporte.

Cada arquitetura fundamenta-se em princípios matemáticos distintos de particionamento do espaço amostral e minimização de erro, apresentando trade-offs específicos em relação à complexidade computacional, interpretabilidade e sensibilidade ao volume de dados (Hastie et.al, 2009).

As Redes Neurais Artificiais, *Artificial Neural Networks* – ANN, constituem modelos computacionais distribuídos e paralelos inspirados na estrutura do córtex biológico. Dentre as diversas tipologias de redes, o Perceptron Multicamadas, *Multilayer Perceptron* – MLP, de alimentação direta, *feedforward*, é a arquitetura mais empregada em engenharia química para a aproximação de funções contínuas não lineares (Bishop, 2006).

Em um MLP, a informação propaga-se unidirecionalmente da camada de entrada para a camada de saída através de uma ou mais camadas intermediárias ocultas. A unidade fundamental de processamento é o neurônio artificial, que executa uma soma ponderada das entradas adicionada de um termo de polarização (*bias*), seguida pela aplicação de uma função de ativação não linear contínua σ :

$$y_j = \sigma \left(\sum_{i=1}^d w_{ji} x_i + b_j \right)$$

onde w_{ji} representa o peso sináptico que conecta a entrada x_i ao neurônio j , e b_j denota o limiar de polarização associado (Haykin, 2009). As funções de ativação conferem à rede a capacidade de capturar comportamentos não lineares complexos. Historicamente, funções sigmóides, como a função logística e a tangente hiperbólica, predominaram em estudos iniciais de processos químicos; contudo, arquiteturas modernas frequentemente recorrem à Unidade Linear Retificada, ReLU, devido à sua eficiência computacional e mitigação do fenômeno de desvanecimento de gradiente, *vanishing gradient*, durante o treinamento profundo (Goodfellow et.al, 2016)

O ajuste dos pesos w dos parâmetros de polarização b é conduzido por métodos de otimização baseados em gradiente, empregando o algoritmo clássico de retropropagação do erro (backpropagation) (Rumelhart et.al, 1986). A retropropagação utiliza a regra da cadeia para calcular analiticamente os gradientes da função de perda em relação a cada

peso da rede, permitindo atualizações iterativas por algoritmos estocásticos, como o otimizador Adam ou rotinas de segunda ordem amortecidas, a exemplo do algoritmo de Levenberg-Marquardt (Bishop, 2006).

As Árvores de Decisão para regressão fundamentam-se na divisão sequencial e hierárquica do espaço de variáveis de entrada em sub-regiões menores e homogêneas, a partir de regras condicionais simples (Breiman et.al, 1984). Em cada nó da estrutura, o algoritmo identifica a variável de processo e o valor limite que proporcionam a maior redução na dispersão dos dados, atribuindo à folha terminal a média das observações ali contidas. Embora ofereçam interpretação visual direta e facilitem a compreensão das relações operacionais, árvores individuais apresentam alta instabilidade e forte propensão ao sobreajuste (*overfitting*), sendo excessivamente sensíveis a pequenas variações e ruídos típicos de medições laboratoriais (Hastie et.al, 2009).

Para superar essa limitação, Breiman (2001) propôs o algoritmo *Random Forest*, que opera pelo princípio de aprendizado por comitê, *ensemble*. O método combina a geração de centenas de árvores de regressão independentes, treinadas a partir de reamostragens aleatórias com reposição da base original, *bagging*, associada à seleção aleatória de um subconjunto restrito de atributos a cada nó de divisão. A predição final resulta da média das respostas de todas as árvores, cancelando a variância individual e tornando o modelo altamente robusto contra ruídos analíticos. Na engenharia de processos, o *Random Forest* destaca-se por dispensar o escalonamento estrito de variáveis e por fornecer a importância relativa de cada parâmetro operacional, *feature importance*, permitindo identificar quantitativamente quais variáveis, como temperatura, concentração ácida ou velocidade de agitação, exercem influência preponderante sobre a taxa de lixiviação.

A Regressão por Vetores de Suporte (Support Vector Regression – SVR) fundamenta-se no princípio da minimização do risco estrutural, proposto por Vapnik (1995), que busca conciliar a acurácia de predição com a baixa complexidade do modelo para garantir boa capacidade de generalização. Diferente dos métodos convencionais de mínimos quadrados, o SVR adota o conceito de tubo de perda ϵ -insensível: define-se uma margem de tolerância ao redor da estimativa na qual os erros de previsão são considerados nulos, penalizando-se apenas os pontos experimentais que ultrapassam essa faixa por meio de um parâmetro de compensação (Smola et.al, 2004).

Dessa forma, a solução obtida depende exclusivamente dos pontos situados sobre ou fora da fronteira desse tubo, denominados vetores de suporte, o que confere esparsidade e estabilidade matemática ao algoritmo (Smola et.al, 2004). Em sistemas químicos, o SVR é amplamente valorizado por constituir um problema de otimização estritamente convexo, ou seja, elimina a armadilha de convergência para mínimos locais, comum em redes neurais, e por manter alto desempenho preditivo mesmo quando treinado com bases de dados reduzidas, cenário característico de ensaios cinéticos de bancada em hidrometalurgia (Hastie et.al, 2009)

3.2.3. Pré-processamento de dados e estratégias de validação

Em processos químicos e hidrometalúrgicos, os dados experimentais e operacionais não devem ser alimentados diretamente em algoritmos de aprendizado de máquina. As variáveis que governam sistemas reacionais heterogêneos apresentam naturezas e ordens de grandeza discrepantes, abrangendo grandezas como temperatura, concentração de reagentes, agitação mecânica, granulometria de sólidos e tempo de residência. A utilização direta dessas variáveis sem tratamento numérico prévio distorce o processo de calibração, o que compromete a convergência dos algoritmos e prejudica a estabilidade das estimativas geradas (Kuhn et.al, 2013).

Dessa maneira, com o intuito de uniformizar a influência das variáveis na função de perda, empregam-se técnicas de escalonamento, destacando-se a normalização linear, *Min-Max Scaling*, e a padronização por escore-z, *StandardScaler*. A normalização projeta os valores em uma faixa delimitada entre 0 e 1, sendo recomendada para redes neurais cujas funções de ativação impõem assíntotas rígidas, enquanto a padronização centraliza os dados na média nula com desvio-padrão unitário, conferindo maior robustez contra dispersões heterogêneas e valores atípicos (Bishop, 2006). Em métodos baseados em distâncias, como a regressão por vetores de suporte (SVR), ou orientados por gradiente descendente, como o perceptron multicamadas (MLP), essas transformações evitam que atributos com magnitudes absolutas elevadas dominem artificialmente o aprendizado, embora modelos baseados em árvores (*Random Forest*) sejam invariantes a escalas monotônicas (Hastie et.al, 2009).

De modo paralelo, a confiabilidade preditiva requer a divisão sistemática dos dados em subconjuntos de treinamento, validação e teste. A partição de treinamento é destinada ao

ajuste dos pesos do modelo, a de validação orienta a sintonia de hiperparâmetros e a contenção do sobreajuste via interrupção antecipada, *early stopping*, e a de teste mede a acurácia final sobre dados independentes (Goodfellow et.al, 2016). Sob o aspecto metodológico, todos os parâmetros de escalonamento estatístico devem ser obtidos exclusivamente a partir do conjunto de treinamento e apenas aplicados às partições subsequentes, prevenindo o vazamento antecipado de informações, *data leakage*, especialmente em processos com dependência temporal, nos quais a separação deve resguardar a independência estatística entre os conjuntos (Von stosch et al., 2014).

3.2.4. Avaliação de desempenho e generalização

Neste sentido, com intuito de encerrar o tópico de aprendizado de máquina, é fundamental dizer que a avaliação de modelos de aprendizado de máquina em engenharia de processos requer critérios quantitativos que calculam a discrepância entre as predições geradas e os dados experimentais de referência. Em tarefas de regressão, essa análise apoia-se tradicionalmente em um conjunto complementar de métricas estatísticas tais como o Coeficiente de Determinação R^2 , a Raiz do Erro Quadrático Médio (RMSE) e o Erro Absoluto Médio (MAE) (Hastie et al, 2009).

Dessa forma, é importante avaliar as principais diferenças e aplicabilidades dessas métricas. Enquanto o R^2 expressa a proporção da variabilidade dos dados explicada pelo modelo em relação a uma média trivial, ele não é capaz de refletir a magnitude física dos desvios. Nesses casos, então, utiliza-se o RMSE, que reporta o erro na mesma unidade da variável de processo investigada (como conversão ou concentração), penalizando desproporcionalmente desvios acentuados por elevar os resíduos ao quadrado. Por fim, o MAE confere peso linear a todas as discrepâncias individuais, oferecendo uma leitura complementar e mais robusta contra a influência de *outliers* frequentes em ensaios laboratoriais (Bishop, 2006).

Além do ajuste numérico, o comportamento preditivo de qualquer algoritmo também é governado pelo dilema viés-variância, no qual o erro de generalização se decompõe em duas fontes antagônicas (Geman et al, 1992). O subajuste, conhecido como *underfitting*, surge quando o modelo exhibe alto viés, decorrente de uma formulação excessivamente simplificada que falha em capturar as dinâmicas não lineares do sistema, gerando erros elevados tanto na calibração quanto no teste. Por outro lado, o sobreajuste, conhecido

como *overfitting*, decorre de uma alta variância estrutural: em vez de apreender o comportamento fenomenológico subjacente, o algoritmo memoriza o ruído e as flutuações estocásticas dos dados de treino, apresentando aderência elevada na etapa de ajuste, mas falhando de forma expressiva ao lidar com dados não observados (Goodfellow et al, 2016).

Portanto, com o intuito de equilibrar essa relação e maximizar a generalização, aplicam-se técnicas de regularização, por exemplo, a penalização da magnitude dos parâmetros e a interrupção antecipada do treinamento, que restringem a complexidade do modelo e impõem superfícies de resposta mais suaves.

Entretanto, mesmo com o emprego de métricas rigorosas e mecanismos de regularização, a utilização isolada de modelos *data driven* esbarra em limitações conceituais severas para a área da Engenharia Química. Conforme adverte Venkatasubramanian (2019), os algoritmos convencionais de aprendizado de máquina são essencialmente estatísticos e correlacionais, desprovidos de noções de causalidade, limites estequiométricos e leis fundamentais de conservação de massa, energia e momento. Por operarem estritamente por interpolação no domínio experimental em que foram calibrados, esses modelos perdem confiabilidade preditiva quando expostos a situações fora da faixa de treinamento, impondo riscos críticos a tarefas de otimização e de escalonamento de processos, nas quais podem gerar previsões fisicamente impossíveis, como conversões que violam limites termodinâmicos ou taxas reacionais negativas (Von stosch et al., 2014).

Diante disso, evidencia-se que o aprendizado de máquina atinge sua maior maturidade na engenharia não pela substituição dos modelos de primeiros princípios, mas pela sua integração coordenada por meio da modelagem híbrida. Nessa abordagem, preserva-se a consistência necessária das equações de balanço macroscópico, enquanto os algoritmos de regressão são encarregados de estimar pontualmente grandezas constitutivas incertas ou complexas demais para descrição analítica estrita, como taxas cinéticas. (Psychogios, 1992). Tais perspectivas fecham a discussão a respeito dos fundamentos de aprendizado de máquina e estabelece a justificativa técnica para as seções subsequentes, abrindo oportunidade para tratar da formulação de arquiteturas híbridas e redes neurais nas separações sólido-líquido.

3.3. APRENDIZADO DE MÁQUINA APLICADO À LIXIVIAÇÃO: AVANÇOS RECENTES E ANÁLISE DO ESTADO DA ARTE

3.3.1. Panorama das Aplicações de Dados em Sistemas de Lixiviação

A modelagem de reatores e pilhas de lixiviação passou por uma reorientação significativa nas últimas décadas. Tradicionalmente, o dimensionamento, a simulação e o controle operacional desses sistemas têm sido fundamentados em correlações empíricas, frequentemente obtidas por regressão, ou na calibração dos modelos fenomenológicos de cinética heterogênea discutidos na Seção 3.1.3.

Embora esses modelos forneçam uma estrutura conceitual indispensável à interpretação dos fenômenos interfaciais, cinéticos e difusivos, sua aplicação direta à polpas minerais complexas e a unidades industriais apresenta limitações recorrentes. A distribuição granulométrica polidispersa, a heterogeneidade mineralógica da ganga, a formação de camadas de produto ou fases passivantes, as variações na porosidade e as oscilações da composição da alimentação introduzem comportamentos não ideais que dificilmente são representados, de maneira simultânea e reprodutível, por formulações analíticas simplificadas.

Nesse contexto, técnicas de aprendizado de máquina, ou *Machine Learning* (ML), vêm sendo investigadas como ferramentas complementares para representar relações multivariáveis e não lineares em processos de dissolução reativa. A revisão conduzida por Saldaña et al. (2022) reúne aplicações de redes neurais artificiais, máquinas de vetores de suporte, redes bayesianas e outros métodos de aprendizado supervisionado na modelagem de diferentes sistemas de lixiviação mineral. Os autores também destacam a necessidade de melhorar a capacidade de generalização desses modelos e de avançar em sua integração com estratégias de simulação, otimização e aplicação industrial.

As aplicações orientadas por dados abrangem sistemas como lixiviação de cobre, biolixiviação, cianetação de ouro e processamento de materiais contendo alumínio. Nesses estudos, variáveis granulométricas e químicas são utilizadas como entradas para a predição da extração metálica ou de parâmetros associados ao desempenho do processo. Apesar dos resultados promissores, modelos puramente orientados por dados permanecem dependentes da representatividade da base de treinamento e podem produzir previsões fisicamente inconsistentes quando aplicados fora do domínio experimental utilizado em sua calibração.

Mais recentemente, a aplicação dessas técnicas expandiu-se para o processamento de minérios de baixo teor e para a recuperação hidrometalúrgica de materiais secundários. Essas duas frentes possuem interesse metodológico para a lixiviação de zinco, pois envolvem matrizes heterogêneas, múltiplas reações simultâneas, variações de composição da alimentação e mecanismos de transporte que nem sempre podem ser descritos adequadamente por um único modelo cinético.

No âmbito dos minérios naturais de baixo teor, a lixiviação redutora de pirolusita, MnO_2 , intensificada por campo elétrico constitui um exemplo representativo. Zhang et al. (2022) avaliaram seis variáveis operacionais: concentração de sulfato ferroso, concentração de ácido sulfúrico, razão líquido-sólido, densidade de corrente, temperatura e tempo de lixiviação. Os autores compararam modelos de regressão linear múltipla, árvore de decisão, Random Forest, perceptron multicamadas, Gradient Boosting Regression e regressão por vetores de suporte.

O modelo de regressão por vetores de suporte apresentou o melhor desempenho no conjunto de avaliação reportado, com $R^2 = 0,92$ e erro quadrático médio de 25,0425, equivalente a uma raiz do erro quadrático médio de aproximadamente 5,005 pontos percentuais. Os resultados indicam que modelos não lineares podem descrever adequadamente relações complexas entre as condições operacionais e a extração metálica, sobretudo quando a base de dados é limitada. Entretanto, como o modelo não incorpora explicitamente balanços de massa, condições de contorno ou restrições termodinâmicas, sua utilização fora do domínio experimental requer cautela.

Outra frente relevante corresponde ao tratamento hidrometalúrgico de materiais provenientes da reciclagem de baterias de íons de lítio. A massa negra, ou black mass, constitui uma matriz polimetálica artificial cuja composição depende da química da bateria, das condições de uso e das etapas de pré-tratamento. Em sistemas baseados em cátodos NMC, podem estar presentes óxidos contendo lítio, níquel, manganês e cobalto, além de carbono grafitico e resíduos dos coletores de corrente de alumínio e cobre.

Nesse campo, dois vetores metodológicos complementares podem ser identificados:

1. Modelagem de ampla abrangência química: direcionada à predição do rendimento de lixiviação em diferentes condições e ao rastreamento preliminar de agentes lixiviantes. Nogueira et al. (2026) desenvolveram uma estrutura baseada em aprendizado de máquina e diferenças pareadas para prever a lixiviação de materiais catódicos de baterias, integrando as predições a indicadores econômicos e ambientais preliminares.
2. Monitoramento dinâmico do estado da lixiviação: direcionado à inferência do avanço

da reação a partir de variáveis instrumentais medidas durante o processo. Song et al. (2025) utilizaram pH, condutividade e temperatura como entradas de um modelo de regressão linear múltipla para estimar os estados de lixiviação de Al, Fe, Ni, Co, Li e Mn em massa negra previamente submetida a tratamento térmico. O modelo apresentou R^2 ajustado médio de 0,9950 e erro médio de predição inferior ou próximo de 1,1%, nas condições experimentais investigadas.

Os resultados de Song et al. (2025) mostram que sinais de sensores em linha podem conter informações suficientes para inferir o avanço da dissolução metálica sem depender exclusivamente de análises laboratoriais defasadas no tempo. Contudo, o modelo desenvolvido é essencialmente correlacional e foi calibrado para uma determinada composição de alimentação e uma faixa específica de condições operacionais. Alterações substanciais na mineralogia, no pré-tratamento térmico, na concentração de ácido ou na razão sólido-líquido podem modificar as relações entre os sinais dos sensores e o estado real da lixiviação.

Em conjunto, esses estudos evidenciam o potencial dos métodos orientados por dados para representar não linearidades, selecionar variáveis relevantes e desenvolver sensores virtuais para processos hidrometalúrgicos. Ao mesmo tempo, destacam limitações relacionadas à extrapolação, à interpretabilidade física e à garantia de consistência das previsões.

Tais limitações fundamentam o desenvolvimento de abordagens híbridas. No contexto deste trabalho, a modelagem híbrida é compreendida como a integração entre um modelo fenomenológico, responsável por representar balanços de massa, relações cinéticas e restrições físico-químicas, e um modelo de aprendizado de máquina, empregado para estimar parâmetros variáveis, corrigir resíduos sistemáticos ou representar fenômenos não descritos explicitamente pela estrutura mecanicista.

Para a lixiviação de zinco, essa estratégia é particularmente relevante porque permite preservar a coerência físico-química do modelo e, simultaneamente, representar efeitos decorrentes da variabilidade mineralógica, da formação de camadas de produto, da presença de espécies interferentes e das mudanças nas condições operacionais. Assim, os modelos híbridos podem oferecer maior capacidade preditiva e melhor potencial de generalização do que modelos exclusivamente mecanicistas ou puramente orientados por dados.

A sistematização das variáveis operacionais, algoritmos, procedimentos de validação e respostas investigadas nos estudos selecionados é apresentada na Tabela XX. Essa comparação fornece a base para identificar os componentes que podem ser transferidos ou adaptados ao desenvolvimento do modelo híbrido de lixiviação de zinco proposto neste trabalho.

Tabela XX – Síntese comparativa de estudos que aplicam métodos orientados por dados à modelagem de sistemas de lixiviação hidrometalúrgica

Estudo	Sistema	<i>Input</i>	<i>Output</i>	Algoritmo	Conclusões e limitações
Nogueira et al. (2026)	Materiais catódicos de baterias Li-íon e diferentes lixiviantes	Composição, temperatura, concentrações dos reagentes, razão S/L, tempo e descritores moleculares	Extração de Li, Ni, Mn e Co	RF, GBR, ANN e modelos com diferenças pareadas	Adequado para triagem de lixiviantes, mas limitado para mecanismos pouco representados nos dados.
Song et al. (2025)	Massa negra pirolisada em lixiviação ácida	pH, condutividade e temperatura	Estado de lixiviação de Al, Fe, Ni, Co, Li e Mn	Regressão linear múltipla e SCM	Permite monitoramento em linha, mas requer recalibração para mudanças na alimentação
Zhang et al. (2022)	Pirolusita sob lixiviação redutora intensificada por campo elétrico	FeSO ₄ , H ₂ SO ₄ , razão L/S, corrente, temperatura e tempo	Extração de Mn	MLR, DT, RF, MLP, GBR e SVR	Representa bem relações não lineares, mas não incorpora restrições físico-químicas.

Saldaña et al. (2022)	Revisão de diferentes sistemas de lixiviação mineral	Variáveis granulométricas, hidráulicas, químicas e operacionais	Extração metálica e parâmetros cinéticos	ANN, SVM, redes bayesianas e métodos de comitê	Destaca o potencial do ML, mas alerta para limitações de generalização e extrapolação.
------------------------------	--	---	--	--	--

Fonte: Elaborado pelos autores a partir de Saldaña et al. (2022), Zhang et al. (2022), Song et al. (2025) e Sosa et al. (2026).

3.3.2. Dinâmica operacional, desempenho algorítmico e limitações dos modelos caixa-preta

Conforme descrito anteriormente na seção 3.1, é possível dizer que a análise dos sistemas de lixiviação descritos na literatura evidencia que a extração metálica resulta da interação entre fenômenos termodinâmicos, cinéticos e de transporte. Dessa forma, variáveis como temperatura, acidez livre, potencial de oxirredução e concentração dos reagentes apresentam efeitos acoplados e frequentemente não lineares. O aumento da acidez, por exemplo, pode favorecer a dissolução mineral, mas também alterar os equilíbrios químicos da solução e contribuir para a formação de precipitados ou camadas de produto que dificultam o transporte de massa. De modo semelhante, a concentração de agentes redutores e a aplicação de campos físicos externos modificam as condições eletroquímicas do sistema e, conseqüentemente, a evolução da extração metálica (Habashi, 1997; Zhang et al., 2022).

Tal complexidade dinâmica tem motivado o desenvolvimento de sensores virtuais para estimar, em tempo real, o avanço da lixiviação. Nessa abordagem, modelos preditivos utilizam séries temporais de variáveis medidas em linha, como pH, condutividade elétrica, temperatura e potencial de oxirredução, em substituição ao uso exclusivo de parâmetros estáticos. Como a dissolução dos sólidos modifica a composição e o equilíbrio iônico do licor, esses sinais fornecem informações indiretas sobre a evolução do processo. Assim, modelos supervisionados podem estimar continuamente o estado reacional da polpa, reduzindo a dependência de amostragens e análises químicas demoradas, embora estas permaneçam necessárias para calibração e validação (Song et al., 2025)

Dentro do contexto do desempenho algorítmico, a literatura demonstra que diferentes arquiteturas de aprendizado de máquina oferecem versatilidade para enfrentar a rigidez dos modelos cinéticos tradicionais. Por exemplo, em sistemas heterogêneos não lineares, métodos como a Regressão por Vetores de Suporte (SVR) e comitês de árvores (*Random Forest* e *Gradient Boosting*) destacam-se pela flexibilidade em mapear interações multivariáveis complexas sem exigir parametrizações analíticas prévias, viabilizando desde a predição da taxa de extração até a triagem ágil de novos solventes e o monitoramento em linha via sensores industriais (Zhang et al., 2022; Song et al., 2025; Nogueira et al., 2026).

Além disso, para contornar a escassez crônica de dados experimentais em bancadas de lixiviação, estratégias avançadas de *data augmentation*, como a *pairwise difference*, têm se mostrado soluções promissoras para expandir a capacidade de aprendizado e fornecer intervalos de incerteza preditiva sem a necessidade de gerar centenas de novos ensaios laboratoriais (Nogueira et al., 2026).

Apesar dessa flexibilidade prática, os modelos puramente caixa-preta apresentam limitações operacionais decisivas. Por serem estritamente correlacionais e desprovidos de causalidade físico-química, esses algoritmos operam com sucesso apenas no domínio de calibração em que foram ajustados. Na prática hidrometalúrgica, pequenas variações operacionais podem introduzir mecanismos termodinâmicos imprevistos, por exemplo a formação de camadas passivantes ou a precipitação secundária de fases insolúveis, que o algoritmo é incapaz de antecipar caso não constem expressamente nos dados de treinamento (Nogueira et al., 2026).

Portanto, o gargalo mais crítico dessas abordagens reside na extrapolação e na ausência de restrições de conservação. Sem a presença da modelagem fenomenológica, algoritmos puramente empíricos tornam-se vulneráveis à geração de estimativas fisicamente inadmissíveis, como recuperações metálicas superiores a 100%, concentrações negativas ou trajetórias que violem os balanços materiais globais (Saldaña et al., 2022; Sansana et al., 2024). Essa constatação não anula o potencial do aprendizado de máquina, mas delimita sua fronteira: a inteligência baseada em dados alcança sua maior maturidade na engenharia quando opera em conjunto com as leis fundamentais da conservação. Estabelece-se, assim, a motivação para a próxima seção de modelagem híbrida, na qual balanços mecanicistas e populacionais impõem a consistência física necessária ao processo de lixiviação de zinco, enquanto os algoritmos de regressão são encarregados de inferir dinamicamente as cinéticas constitutivas complexas (von Stosch et al., 2014; Sansana et al., 2024).

3.4. MODELAGEM HÍBRIDA

3.4.1. Conceito e motivação

A modelagem matemática de processos químicos e metalúrgicos tem sido historicamente norteadada por dois paradigmas contrastantes: a modelagem fenomenológica clássica, fundamentada em primeiros princípios (First-Principles Models (FPM) ou white-box), e a modelagem puramente empírica baseada em dados (Data-Driven Models (DDM) ou black-box) (Sansana et al., 2021; Schweidtmann et al., 2023). Os modelos white-box derivam da aplicação direta das leis universais de conservação de massa, quantidade de movimento e energia, associadas a relações constitutivas de transporte e equilíbrio termodinâmico que confere aos FPMs uma transparência para o entendimento dos mecanismos operantes, garantindo coerência fenomenológica e alta capacidade teórica de generalização (Shah et al., 2025).

Contudo, a implementação desses modelos para sistemas industriais reais comumente esbarra no fenômeno do descompasso estrutural planta-modelo (plant-model mismatch) (Chen et al., 2020). Na prática, reatores químicos e operações de lixiviação exibem não-linearidades significativas, escoamentos hidrodinamicamente não ideais, efeitos de envenenamento e reações secundárias que dificilmente podem ser descritos de forma analítica exata. Para que essas formulações sejam computacionalmente viáveis, os modeladores frequentemente precisam adotar hipóteses bastante idealizadas, como mistura perfeita, condições estritamente isotérmicas e parâmetros cinéticos constantes ao longo do tempo. Além disso, esses modelos costumam exigir a calibração laboriosa de grandezas que não podem ser medidas diretamente em linha (von Stosch et al., 2014; Sansana et al., 2024).

Por outro lado, os avanços recentes nas técnicas de aprendizado de máquina apresentadas na Seção 3.2 impulsionaram o desenvolvimento de modelos puramente orientados por dados. Algoritmos supervisionados, como o Perceptron Multicamadas (MLP), as Florestas Aleatórias (Random Forest) e a Regressão por Vetores de Suporte (SVR), têm demonstrado elevada capacidade de capturar dinâmicas não lineares complexas diretamente de séries temporais de processo, sem a necessidade de formulações fenomenológicas definidas anteriormente (Mitchell, 1997). No entanto, a aplicação isolada desses métodos na engenharia de processos ainda apresenta limitações importantes. Por operarem essencialmente como “caixas-pretas” estatísticas, os modelos

puramente empíricos não conferem significado físico aos seus parâmetros internos, dependem de bases de dados extensas e de boa qualidade e podem produzir previsões incompatíveis com princípios fundamentais de conservação.

Entre os resultados fisicamente inconsistentes, existem exemplos como: frações de conversão superiores a 100% e perdas aparentes de massa (Shah et al., 2025). Além disso, quando aplicados a regimes operacionais não representados nos dados de treinamento, conhecidos como condições fora do domínio (out-of-domain (OOD)), esses modelos podem apresentar uma redução de sua capacidade preditiva, uma vez que seu desempenho tende a ser mais confiável em situações de interpolação do que de extrapolação (Sansana et al., 2024).

A Modelagem Híbrida, também conhecida como grey-box ou semiparamétrica, surge justamente da integração entre essas duas vertentes e seu princípio central consiste em combinar funções complementares: as leis fundamentais de conservação que estabelecem uma estrutura fisicamente consistente, enquanto os modelos de aprendizado de máquina estimam termos constitutivos complexos, incertos ou sujeitos a variações dinâmicas (Shah et al., 2025). Do ponto de vista estatístico, essa combinação favorece o equilíbrio entre viés e variância (bias-variance trade-off), pois os balanços mecanicistas restringem o aprendizado a soluções fisicamente plausíveis, diminuindo a variância do estimador e reduzindo a quantidade de dados necessária para alcançar um desempenho satisfatório. Em contrapartida, a flexibilidade não linear dos métodos de aprendizado de máquina ajuda a superar limitações decorrentes de hipóteses teóricas simplificadoras, reduzindo o viés e aumentando a fidelidade das previsões dinâmicas (Sansana et al., 2024).

3.4.2. Taxonomia estrutural: Hybrid Modeling Diamond

A forma como os módulos mecanicistas baseados em primeiros princípios (fp) e os estimadores orientados por dados (fd) são matematicamente integrados determinam a arquitetura do modelo híbrido. Sansana et al. (2024) sistematizaram essas possibilidades por meio do conceito de Hybrid Modeling Diamond, que classifica as formas de integração em quatro arquiteturas fundamentais.




Figura XX: Hybrid Models Diamond proposto por Sansana et al. (2024).

Fonte: Sansana et al. (2024).

3.4.2.1. Arquitetura serial (Serial Hybrid: DDM para FPM)

Na configuração serial direta, o modelo orientado por dados atua como um estimador em linha de parâmetros constitutivos que não são conhecidos ou que não podem ser determinados diretamente. Os valores estimados pelo DDM são, então, utilizados como entradas nas equações diferenciais de conservação do modelo baseado em primeiros princípios.




Figura XX: Representação esquemática da arquitetura serial.

Fonte: Sansana et al. (2024).

Essa arquitetura apresenta três vantagens principais:

- Preservação dos balanços: os estados do processo são calculados a partir da integração das equações de conservação do FPM. Dessa forma, as previsões permanecem sujeitas às restrições impostas pelos balanços estequiométricos e materiais globais (Sansana et al., 2024);
- Interpretabilidade dos parâmetros: a saída da rede neural está associada a uma variável cujo significado físico é conhecido, como constantes cinéticas, coeficientes convectivos ou velocidades superficiais de dissolução. Isso permite avaliar se os valores estimados são coerentes com o comportamento esperado segundo as teorias físico-químicas (Sansana et al., 2024);
- Maior capacidade de extrapolação: como a evolução temporal do sistema continua fundamentada nas leis de conservação, a arquitetura tende a apresentar maior robustez quando aplicada a condições operacionais diferentes daquelas utilizadas durante sua calibração (Sansana et al., 2024).

A calibração do modelo serial pode ser realizada de duas maneiras. Na abordagem sequencial, os parâmetros pontuais são inicialmente identificados a partir dos dados e, em seguida, utilizados no treinamento do DDM. Já na abordagem simultânea, também denominada end-to-end, o DDM é treinado em conjunto com a integração das equações diferenciais. Esse procedimento pode ser viabilizado por técnicas de diferenciação automática ou por métodos adjuntos (Sansana et al., 2024).

3.4.2.2. **Arquitetura paralela cooperativa: modelagem residual**

Na arquitetura paralela cooperativa, o modelo de primeiros princípios (FPM) utiliza parâmetros nominais conhecidos para produzir uma previsão inicial fundamentada nas relações físicas do processo. Paralelamente, um modelo orientado por dados, como uma rede neural perceptron multicamadas (MLP) ou uma máquina de vetores de suporte para regressão (SVR), é treinado para estimar a diferença entre a previsão mecanicista e os valores efetivamente observados no processo.




Figura XX: Representação esquemática da arquitetura paralela cooperativa.

Fonte: Sansana et al. (2024).

Essa estrutura é especialmente útil quando o modelo mecanicista apresenta limitações conhecidas ou simplificações que resultam em desvios sistemáticos e, nesse caso, o componente orientado por dados atua como um termo de correção, compensando as discrepâncias que o FPM, isoladamente, não consegue representar.

Apesar dessa vantagem, Sansana et al. (2024) destacam uma limitação importante. Quando o modelo é aplicado em condições muito diferentes daquelas utilizadas no treinamento, o componente orientado por dados pode produzir correções sem consistência física. Isso ocorre porque o termo residual aprendido não está necessariamente submetido às mesmas restrições mecanicistas que governam o FPM, o que pode comprometer a confiabilidade das previsões em situações de extrapolação acentuada.

3.4.2.3. **Arquitetura paralela competitiva: combinação de modelos**

Na arquitetura paralela competitiva, o FPM e o DDM estimam, de forma independente, a mesma variável do processo. As previsões geradas pelos dois modelos são posteriormente combinadas por meio de uma média ponderada convexa, definida a partir

de um fator de calibração.




Figura XX: Representação esquemática da arquitetura paralela competitiva.

Fonte: Sansana et al. (2024).

O fator de ponderação determina a contribuição de cada modelo para a previsão final e costuma ser ajustado por mínimos quadrados com base no conjunto de validação. Dessa forma, modelos que apresentam melhor desempenho ou maior confiabilidade recebem maior peso na estimativa combinada.

3.4.2.4. **Arquitetura híbrida aumentada por conhecimento (Knowledge-Augmented Hybrid, KAH)**

A arquitetura híbrida aumentada por conhecimento (KAH) busca enriquecer o conjunto de informações fornecido ao modelo de aprendizado de máquina. Nessa configuração, as variáveis operacionais medidas são combinadas com as trajetórias preliminares dos estados do processo, calculadas por um modelo fenomenológico baseado em primeiros princípios.




Figura XX: Representação esquemática da arquitetura híbrida aumentada por conhecimento.

Fonte: Sansana et al. (2024).

A incorporação das previsões do modelo fenomenológico permite que o regressor tenha acesso não apenas aos dados medidos, mas também a informações previamente estruturadas pelas leis físicas que governam o processo. Assim, o aprendizado ocorre sobre um espaço de atributos que já contém relações associadas aos princípios de conservação. Essa combinação contribui para que o modelo identifique relações não lineares de maneira mais consistente, favorecendo sua capacidade de generalização e reduzindo a suscetibilidade ao sobreajuste (Sansana et al., 2024).

3.4.3. O framework de extrapolação e transferência de aprendizado (transfer learning)

Na indústria de transformação, mudanças nas características das matérias-primas, variações na pureza dos solventes e alterações nas condições de mercado podem exigir que plantas químicas e hidrometalúrgicas operem em condições diferentes daquelas utilizadas no desenvolvimento de seus modelos. Durante esses períodos de transição, o processo pode alcançar regiões operacionais ainda pouco conhecidas, para as quais os dados disponíveis são escassos ou até mesmo inexistentes.

Com o objetivo de lidar com esse cenário, Sansana et al. (2024) propuseram um framework evolutivo de modelagem de processos, estruturado em três estágios. Essa estrutura acompanha o aumento gradual da disponibilidade de dados na nova região operacional, partindo da extrapolação direta, passando pela transferência de aprendizado e chegando ao retreinamento completo do modelo.




Figura XX: Representação do framework evolutivo de modelagem de processos.

Fonte: Sansana et al. (2024).

No primeiro estágio (extrapolação direta sem dados da nova região), o processo deixa a Região Operacional A e passa a operar em uma nova Região B, para a qual ainda não existem dados disponíveis e, diante dessa limitação, o modelo originalmente treinado na Região A é aplicado diretamente às novas condições, sem qualquer atualização prévia.

Nesse cenário, modelos desenvolvidos exclusivamente a partir de dados tendem a apresentar uma perda significativa de desempenho, uma vez que precisam prever o comportamento do processo fora do domínio representado durante o treinamento. As arquiteturas híbridas, por sua vez, tendem a preservar maior estabilidade e coerência nas previsões, pois parte de sua estrutura permanece fundamentada nas leis de conservação e no conhecimento mecanicista do processo (Sansana et al., 2024).

Após um período inicial de operação na Região B, alguns dados começam a ser coletados, como medições pontuais obtidas ao longo de uma semana. Entretanto, essa quantidade ainda pode ser insuficiente para treinar um novo modelo puramente orientado por dados desde o início, especialmente devido ao risco de sobreajuste. Assim, no estágio 2 (aprendizado por transferência (transfer learning) com dados escassos), utiliza-se o aprendizado por transferência (transfer learning).

O modelo híbrido desenvolvido para a Região A passa a atuar como modelo-fonte (source

model), permitindo que o conhecimento adquirido anteriormente seja aproveitado na adaptação às novas condições operacionais. As equações mecanicistas e as representações internas já aprendidas pela rede neural são mantidas, enquanto apenas uma camada adicional de correção é ajustada com os dados disponíveis na Região B. Essa estratégia dá origem a configurações como TL-KAH e TL-PH.

Nos estudos conduzidos por Sansana et al. (2024), essa abordagem permitiu alcançar desempenho preditivo comparável ao de modelos puramente empíricos utilizando até 80% menos dados. Esse resultado indica que a incorporação do conhecimento físico prévio pode reduzir a quantidade de informações necessária para adaptar o modelo a um novo regime operacional.

À medida que a operação na Região B prossegue, forma-se um conjunto de dados mais amplo e estatisticamente representativo das novas condições e, nesse momento, a arquitetura híbrida pode ser recalibrada de forma global, utilizando todo o histórico acumulado na nova região operacional, obtendo o 3º estágio (retreinamento com dados abundantes).

O modelo resultante passa, então, a ser especificamente ajustado às características da Região B, fornecendo suporte à operação contínua, ao monitoramento e ao controle da planta em condições estáveis de funcionamento.

3.4.4. Parâmetros para a seleção de arquiteturas e aplicação em sistemas de lixiviação

Com base nas evidências experimentais analisadas, Sansana et al. (2024) propuseram algumas diretrizes práticas para auxiliar na escolha da arquitetura híbrida mais adequada às características do processo e aos objetivos da modelagem:

- Quando o modelo mecanicista é bem estabelecido e representa adequadamente os balanços de conservação, mas depende de parâmetros cinéticos ou de transporte difíceis de determinar, a arquitetura serial, na qual o DDM fornece informações ao FPM, apresenta-se como uma alternativa particularmente adequada. Essa configuração preserva as restrições físicas impostas pelo modelo de primeiros princípios e mantém a interpretabilidade dos parâmetros estimados;
- Porém, quando o modelo de primeiros princípios apresenta simplificações ou limitações estruturais, mas ainda descreve satisfatoriamente o comportamento

geral do processo, a arquitetura paralela cooperativa pode ser utilizada para corrigir diferenças sistemáticas entre as previsões mecanicistas e os dados experimentais e a sua aplicação é especialmente conveniente em domínios operacionais conhecidos e relativamente controlados;

- Entretanto, quando a prioridade é obter maior capacidade de generalização em condições distintas daquelas utilizadas no treinamento, incluindo situações de extrapolação e transferência de aprendizado entre unidades industriais, a arquitetura KAH tende a apresentar maior robustez. Isso ocorre porque o modelo orientado por dados recebe, além das variáveis medidas, informações previamente estruturadas pelo modelo mecanicista.

As contribuições teóricas e metodológicas de Sansana et al. (2024) apresentam uma relação direta com os desafios encontrados na modelagem da lixiviação sulfúrica de concentrados ustulados de zinco, discutidos por Bortot Coelho (2017) e Balarini et al. (2025). Conforme discutido nas Seções 3.1.3. e 3.1.4., a dissolução ocorre em uma população de partículas minerais com diferentes tamanhos e características, exigindo uma representação capaz de acompanhar a evolução da distribuição granulométrica ao longo do tempo.

Na abordagem hidrometalúrgica convencional, esse comportamento pode ser descrito por meio de um modelo de balanço populacional (Population Balance Model, PBM), acoplado ao balanço estequiométrico associado ao consumo de reagentes e à dissolução do zinco. Essa formulação mecanicista fornece a base física necessária para o desenvolvimento de arquiteturas híbridas aplicadas ao processo de lixiviação.

Nota: inserir as equações do balanço populacional e do balanço estequiométrico referentes à lixiviação de zinco. - Resolver depois

Conforme observado por Bortot Coelho (2017), os modelos mecanicistas avaliados apresentaram limitações na representação da redução acentuada da taxa de extração após os minutos iniciais da lixiviação. Esse comportamento pode estar associado a fenômenos não lineares que não foram explicitamente incorporados ao modelo, como o efeito do íon comum provocado pelo aumento da concentração de Zn^{2+} , o acúmulo de sulfatos no licor e a menor solubilidade da ferrita de zinco.

Para representar essa diferença entre o comportamento previsto e os resultados experimentais, Bortot Coelho (2017) introduziu uma correlação empírica complementar, caracterizada por um parâmetro estático de ajuste, denominado α .

Nota: inserir a equação cinética modificada proposta por Bortot Coelho (2017), incluindo o parâmetro empírico α . - Resolver depois

A aplicação dos conceitos apresentados por Sansana et al. (2024) oferece uma alternativa para tornar essa correção mais flexível e dependente das condições do processo, pois, em uma arquitetura híbrida serial, na qual o modelo orientado por dados fornece informações ao modelo de balanço populacional, o parâmetro estático α pode ser substituído por uma estimativa dinâmica produzida por um regressor supervisionado, como uma MLP ou uma SVR, conforme discutido na Seção 3.2.

Nessa configuração, o módulo orientado por dados estima, em linha, a velocidade instantânea de redução do diâmetro das partículas a partir das condições do licor e das características da fase sólida. Entre as possíveis variáveis de entrada estão a acidez livre, a temperatura, a razão molar entre os reagentes e o tamanho médio das partículas. A estimativa obtida é então utilizada pelo solucionador mecanicista do balanço populacional para calcular a evolução da distribuição de tamanhos e da conversão ao longo do processo.




Figura XX: Diagrama de blocos da arquitetura híbrida serial aplicada à lixiviação de zinco.

Fonte: Elaboração própria.

Essa abordagem contribui como uma representação dinâmica das limitações cinéticas em que, em vez de utilizar apenas um parâmetro empírico constante, o modelo orientado por dados permite estimar uma correção que varia de acordo com o estado do processo. Dessa forma, torna-se possível representar a desaceleração da extração observada experimentalmente sem recorrer exclusivamente a um fator estático de ajuste;

Adicionalmente, existe a preservação da consistência física, pois como a evolução dos estados continua sendo calculada pelo modelo de balanço populacional, as previsões permanecem vinculadas aos balanços de conservação e às restrições físicas incorporadas ao FPM. Condições adicionais podem ser impostas ao modelo para manter a conversão mássica dentro do intervalo fisicamente admissível, entre 0 e 100%;

Além disso, existe a possibilidade de transferência entre escalas, uma vez que o modelo híbrido calibrado a partir de ensaios cinéticos descontínuos em escala de bancada pode

servir como ponto de partida para representar cascatas contínuas de reatores CSTR em escalas piloto ou industrial. Seguindo o segundo estágio do framework de Sansana et al. (2024), a estrutura mecanicista pode ser preservada, enquanto apenas as camadas finais ou corretivas do estimador são ajustadas com os dados disponíveis na planta contínua.

4. MATERIAIS E MÉTODOS

4.1. PROCEDIMENTOS EXPERIMENTAIS

4.2. AA

4.3. AA

5. RESULTADOS E DISCUSSÃO

5.1. AA

5.2. AA

5.3. AA

5.4. AA

6. CONCLUSÕES

7. REFERÊNCIAS BIBLIOGRÁFICAS

AIZHULOV, M. et al. Fast surrogate models for in-situ recovery of uranium using artificial neural networks. *Hydrometallurgy*, v. 224, p. 106260, 2024.

ALVÁN OLIVEIRA, C. et al. Predictive modeling of gold and silver recovery using random forest in Pachuca agitation tanks. *Minerals Engineering*, v. 195, p. 108020, 2023.

BALARINI, J. C. Estudo Cinético do Ustulado de Zinco da Votorantim Metais: Mecanismo Não Catalítico Associado à Caracterização e à Determinação de Tempos de Residência. 2009. 238 f. Tese (Doutorado em Engenharia Química) – Departamento de Engenharia Química, Universidade Federal de Minas Gerais, Belo Horizonte, 2009.

BALARINI, J. C.; ARAÚJO, E. M. R.; BORTOT COELHO, F. E.; POLLI, L. O.; KONZEN, C.; MIRANDA, T. L. S.; SALUM, A. Leaching kinetics of roasted zinc concentrate in sulphuric acid solutions. *Revista Observatorio de la Economía Latinoamericana*, v. 23, n. 11, p. 1–26, 2025.

BALARINI, J. C.; POLLI, L. O.; MIRANDA, T. L. S.; CASTRO, R. M. Z.; SALUM, A. Importance of roasted sulphide concentrates characterization in the hydrometallurgical extraction of zinc. *Minerals Engineering*, v. 21, n. 1, p. 100–110, 2008.

BASIT, A.; UYAR, T. Stacking ensemble machine learning for the prediction of copper extraction from brass smelting slags. *Journal of Cleaner Production*, v. 440, p. 140880, 2025.

BIRD, R. B.; STEWART, W. E.; LIGHTFOOT, E. N. *Transport Phenomena*. 2. ed. New York: John Wiley & Sons, 2002.

BISCHOFF, K. B. Accuracy of the pseudo steady state approximation for moving boundary diffusion problems. *Chemical Engineering Science*, v. 18, n. 11, p. 711–713, 1963.

BISHOP, C. M. *Pattern Recognition and Machine Learning*. New York: Springer, 2006.

BORTOT COELHO, F. E. Desenvolvimento e Validação de um Modelo de Balanço Populacional para a Lixiviação de um Concentrado Ustulado de Zinco em Bancada e em Escala Piloto. 2017. 240 f. Dissertação (Mestrado em Engenharia Metalúrgica, Materiais

e de Minas) – Escola de Engenharia, Universidade Federal de Minas Gerais, Belo Horizonte, 2017.

BORTOT COELHO, F. E.; BALARINI, J. C.; ARAÚJO, E. M. R.; MIRANDA, T. L. S.; PERES, A. E. C.; MARTINS, A. H.; SALUM, A. A population balance approach to predict the performance of continuous leaching reactors: Model validation in a pilot plant using a roasted zinc concentrate. *Hydrometallurgy*, v. 194, p. 105301, 2020.

BRAVO-GUTIÉRREZ, E. et al. Kinetic evaluation and parameter estimation in copper oxide vat leaching. *Minerals*, v. 16, n. 2, p. 145, 2026.

BREIMAN, L. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.

BREIMAN, L.; FRIEDMAN, J. H.; OLSHEN, R. A.; STONE, C. J. Classification and Regression Trees. Belmont: Wadsworth, 1984.

BRIERLEY, J. A.; BRIERLEY, C. L. Present and future commercial applications of biohydrometallurgy. *Hydrometallurgy*, v. 59, n. 2–3, p. 233–239, 2001.

CHEN, Y.; IERAPETRITOU, M. A framework of hybrid model development with identification of plant-model mismatch. *AIChE Journal*, v. 66, n. 10, p. e16996, 2020.

CHU, Y.; HAHN, J. Parameter set selection for estimation of nonlinear dynamic systems. *AIChE Journal*, v. 53, n. 11, p. 2858–2870, 2007.

CLAUDE, J. et al. Multi-objective optimization of copper extraction from contaminated soils using neural networks and adaptive neuro-fuzzy inference systems. *Journal of Environmental Management*, v. 370, p. 122450, 2025.

CRUNDWELL, F. K. Progress in the mathematical modelling of leaching reactors. *Hydrometallurgy*, v. 39, n. 1–3, p. 321–335, 1995.

CRUNDWELL, F. K.; BRYSON, A. W. The modelling of particulate leaching reactors – the population balance approach. *Hydrometallurgy*, v. 29, n. 1–3, p. 275–295, 1992.

CRUNDWELL, F. K.; MOATS, M. S.; RAMACHANDRAN, V.; ROBINSON, T. G.; DAVENPORT, W. G. *Extractive Metallurgy of Nickel, Cobalt and Platinum Group Metals*. Amsterdam: Elsevier, 2011.

- DA ROCHA, S. D. F. et al. Leaching kinetics of chalcopyrite in acidic ferric sulfate solutions: shrinking core model. *Hydrometallurgy*, v. 138, p. 110–118, 2013.
- DICKINSON, C. F.; HEAL, G. R. Solid-state reactions: models, kinetics, and mechanisms. *Thermochimica Acta*, v. 340, p. 89–103, 1999.
- DIPALI, S. et al. Machine learning-driven optimization of rare earth elements extraction from chlorinated NdFeB magnets. *Separation and Purification Technology*, v. 345, p. 127320, 2024.
- DONG, Z. et al. Dynamic modeling and sliding-window LSTM prediction of gold dissolution in industrial Pachuca tank circuits. *Hydrometallurgy*, v. 219, p. 106095, 2023.
- EBRAHIMZADE, M. et al. Artificial neural network modeling of heavy metals leaching from spent lithium-ion batteries. *Journal of Power Sources*, v. 390, p. 24–32, 2018.
- FENG, X. et al. Sustainable selective leaching of lithium and iron from spent LiFePO₄ cathodes: kinetics and mechanism. *Green Chemistry*, v. 27, p. 1120–1132, 2025.
- FILIPPOU, D.; DEMOPOULOS, G. P. Chemical reaction and mass transfer during leaching of roasted zinc concentrates. *Hydrometallurgy*, v. 28, n. 3, p. 301–318, 1992.
- FREE, M. L. *Hydrometallurgy: Fundamentals and Applications*. Hoboken: John Wiley & Sons, 2013.
- GEMAN, S.; BIENENSTOCK, E.; DOURSAT, R. Neural networks and the bias/variance dilemma. *Neural Computation*, v. 4, n. 1, p. 1–58, 1992.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge: MIT Press, 2016.
- GUPTA, C. K.; MUKHERJEE, T. K. *Hydrometallurgy in Extraction Processes*. Boca Raton: CRC Press, 1990. v. 1.
- HABASHI, F. *Principles of Extractive Metallurgy: Hydrometallurgy*. New York: Gordon and Breach, 1997. v. 2.
- HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2. ed. New York: Springer, 2009.

HAYKIN, S. *Neural Networks and Learning Machines*. 3. ed. Upper Saddle River: Pearson, 2009.

HERBST, J. A. Rate Processes in Multiparticle Metallurgical Systems. In: SOHN, H. Y.; WADSWORTH, M. E. (Eds.). *Rate Processes of Extractive Metallurgy*. Boston: Springer US, 1979. p. 53–112.

JACKSON, E. *Hydrometallurgical Extraction and Reclamation*. New York: Halsted Press, 1986.

KIM, S. et al. High-pressure oxidative acid leaching of copper slag: ensemble machine learning and kinetic verification. *Journal of Hazardous Materials*, v. 501, p. 138900, 2026.

KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. In: *International Conference on Learning Representations (ICLR)*, Toulon, 2017.

KUHN, M.; JOHNSON, K. *Applied Predictive Modeling*. New York: Springer, 2013.

LEBLANC, S. E.; FOGLER, H. S. Population balance modeling of the dissolution of polydisperse solids: Rate limiting regimes. *AIChE Journal*, v. 33, n. 1, p. 54–63, 1987.

LEVENSPIEL, O. *Engenharia das Reações Químicas*. 3. ed. São Paulo: Edgard Blücher, 2000.

MATHABA, M.; BANZA, A. N. Modeling the leaching of copper-cobalt oxidized ores using artificial neural networks. *Minerals Engineering*, v. 210, p. 108650, 2024.

MITCHELL, T. M. *Machine Learning*. New York: McGraw-Hill, 1997.

MONDAL, S. et al. Machine learning-assisted recovery of gallium and germanium from zinc plant residue jarosite cakes. *Hydrometallurgy*, v. 235, p. 106380, 2026.

MOUSA, K. M.; NAJEM, S. A. Kinetic modeling of heterogeneous fluid-solid non-catalytic reactions: shrinking core vs. progressive conversion. *Journal of Chemical Engineering & Technology*, v. 47, n. 4, p. 512–525, 2024.

MURPHY, K. P. *Machine Learning: A Probabilistic Perspective*. Cambridge: MIT Press, 2012.

- NIE, Z. et al. Multi-scale reactive transport and machine learning optimization of copper sulfide heap bioleaching. *Bioresource Technology*, v. 415, p. 131800, 2026.
- NOGUEIRA, C. et al. Predictive models for selective recovery of transition metals from spent lithium-ion battery black mass. *Resources, Conservation and Recycling*, v. 220, p. 108350, 2026.
- NYEMBWE, D. et al. Atmospheric and pressure leaching of pentlandite-rich flotation tailings: experimental and phenomenological assessment. *Minerals*, v. 16, n. 1, p. 89, 2026.
- OLIVEIRA, R. Combining first principles modelling and artificial neural networks: a general framework. *Computers & Chemical Engineering*, v. 28, n. 5, p. 755–766, 2004.
- OUASSEL, A. et al. Uranium extraction from Tahaggart sandstone ore: vat leaching kinetics and numerical simulation. *Journal of Radioanalytical and Nuclear Chemistry*, v. 334, p. 1125–1138, 2025.
- PAHARI, S.; SHAH, P.; KWON, J. S.-I. Unveiling latent chemical mechanisms: Hybrid modeling for estimating spatiotemporally varying parameters in moving boundary problems. *Industrial & Engineering Chemistry Research*, v. 63, n. 3, p. 1501–1514, 2024.
- POURBAIX, M. *Atlas of Electrochemical Equilibria in Aqueous Solutions*. 2. ed. Houston: NACE, 1974.
- PRADHAN, N. et al. Heap bioleaching of chalcopyrite: a review. *Minerals Engineering*, v. 21, n. 5, p. 355–365, 2008.
- PROSSER, A. P. The interpretation of rate data in hydrometallurgy: determination of controlling mechanisms. *Hydrometallurgy*, v. 42, n. 2, p. 195–216, 1996.
- PSICHOGIOS, D. C.; UNGAR, L. H. A hybrid neural network-first principles approach to process modeling. *AIChE Journal*, v. 38, n. 10, p. 1499–1511, 1992.
- QI, Y.; MENG, X. TimeGAN and transformer-based surrogate modeling for dynamic cobalt and lithium leaching from spent black mass. *Chemical Engineering Journal*, v. 505, p. 157200, 2026.

RAISSI, M.; PERDIKARIS, P.; KARNIADAKIS, G. E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, v. 378, p. 686–707, 2019.

RAZZANI, N. et al. Kinetic modeling and artificial neural network optimization of copper leaching from flash furnace flue dusts. *Journal of Environmental Chemical Engineering*, v. 14, n. 2, p. 112100, 2026.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. *Nature*, v. 323, n. 6088, p. 533–536, 1986.

RUSSELL, S.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 3. ed. Upper Saddle River: Prentice Hall, 2010.

SALDAÑA, M. et al. Application of Machine Learning in Hydrometallurgical Processes: A Systematic Review. *Minerals*, v. 12, n. 9, p. 1152, 2022.

SANSANA, J.; JOSWIAK, M. N.; CASTILLO, I.; WANG, Z.; RENDALL, R.; CHIANG, L. H.; REIS, M. S. Recent trends on hybrid modeling for Industry 4.0. *Computers & Chemical Engineering*, v. 151, p. 107365, 2021.

SANSANA, J.; RENDALL, R.; CASTILLO, I.; CHIANG, L.; REIS, M. S. Hybrid modeling for improved extrapolation and transfer learning in the chemical processing industry. *Chemical Engineering Science*, v. 300, p. 120568, 2024.

SCHWEIDTMANN, A. M.; ZHANG, D.; VON STOSCH, M. A review and perspective on hybrid modelling methodologies. *Digital Chemical Engineering*, v. 9, p. 100136, 2023.

SCOTT, P. D. et al. The dissolution of zinc calcine in sulphuric acid: kinetic modeling and simulation. *Metallurgical Transactions B*, v. 17, n. 3, p. 485–493, 1986.

SHAH, P.; PAHARI, S.; BHAVSAR, R.; KWON, J. S.-I. Hybrid modeling of first-principles and machine learning: A step-by-step tutorial review for practical implementation. *Computers & Chemical Engineering*, v. 194, p. 108926, 2025.

SHAH, P.; SHERIFF, M. Z.; BANGI, M. S. F.; KRAVARIS, C.; KWON, J. S.-I.; BOTRE, C.; HIROTA, J. Deep neural network-based hybrid modeling and experimental validation

for an industry-scale fermentation process: Identification of time-varying dependencies among parameters. *Chemical Engineering Journal*, v. 441, p. 135643, 2022.

SHAH, P.; SHERIFF, M. Z.; BANGI, M. S. F.; KRAVARIS, C.; KWON, J. S.-I.; BOTRE, C.; HIROTA, J. Multi-rate observer design and optimal control to maximize productivity of an industry-scale fermentation process. *AIChE Journal*, v. 69, n. 2, p. e17946, 2023.

SITAPURE, N.; KWON, J. S.-I. Introducing hybrid modeling with time-series-transformers: A comparative study of series and parallel approach in batch crystallization. *Industrial & Engineering Chemistry Research*, v. 62, n. 49, p. 21278–21291, 2023.

SMOLA, A. J.; SCHÖLKOPF, B. A tutorial on support vector regression. *Statistics and Computing*, v. 14, n. 3, p. 199–222, 2004.

SOHN, H. Y.; WADSWORTH, M. E. *Rate Processes of Extractive Metallurgy*. Boston: Springer US, 1979.

SONG, Q. et al. Coupling unreacted shrinking core model and multiple linear regression for enhanced selective leaching of transition metals from spent cathodes. *Chemical Engineering Journal*, v. 502, p. 157920, 2025.

SONG, Y. et al. Machine learning evaluation of non-metallic inclusion dissolution kinetics in secondary steelmaking slags. *ISIJ International*, v. 66, n. 3, p. 412–421, 2026.

SOSA, M. et al. Predictive modeling of lithium extraction from spodumene concentrates using tree-based ensemble algorithms. *Hydrometallurgy*, v. 238, p. 106450, 2026.

SURYA, I. et al. High-pressure acid leaching of Indonesian limonite-saprolite nickel ores: kinetics and machine learning modeling. *Hydrometallurgy*, v. 231, p. 106290, 2025.

SUTTON, R. S.; BARTO, A. G. *Reinforcement Learning: An Introduction*. 2. ed. Cambridge: MIT Press, 2018.

SZEKELY, J.; EVANS, J. W.; SOHN, H. Y. *Gas-Solid Reactions*. New York: Academic Press, 1976.

THOMPSON, M. L.; KRAMER, M. A. Modeling chemical processes using prior

knowledge and neural networks. *AIChE Journal*, v. 40, n. 8, p. 1328–1340, 1994.

VAPNIK, V. N. *The Nature of Statistical Learning Theory*. New York: Springer-Verlag, 1995.

VENKATASUBRAMANIAN, V. The promise of artificial intelligence in chemical engineering: Is it here, finally? *AIChE Journal*, v. 65, n. 1, p. 466–472, 2019.

VON STOSCH, M.; OLIVEIRA, R.; PERES, J.; DE AZEVEDO, S. F. Hybrid semi-parametric modeling in process systems engineering: past, present and future. *Computers & Chemical Engineering*, v. 60, p. 86–101, 2014.

WENG, W. et al. Advanced modeling of atmospheric copper slag leaching using boosted regression trees. *Minerals Engineering*, v. 222, p. 108780, 2025.

ZENG, L. et al. Selective fluoride and aluminum recovery from spent potlining: machine learning screening and kinetic validation. *Journal of Cleaner Production*, v. 445, p. 141320, 2026.

ZHANG, L. et al. Review of machine learning applications in extractive metallurgy and mineral processing. *Mineral Processing and Extractive Metallurgy Review*, v. 43, n. 5, p. 612–635, 2022.

ZHOU, X. et al. Leaching kinetics and artificial neural network modeling of zinc and manganese extraction from roasted zinc-manganese dust. *Hydrometallurgy*, v. 218, p. 106110, 2023.

8. APÊNDICES

APÊNDICE A - XX

Este apêndice apresenta xxxx

